VILLE DE LIÈGE

Institut de Technologie Enseignement de Promotion sociale

Année académique 2021 – 2022

Développement d'un codec audio AAC : optimisation de l'algorithme MDCT pour l'architecture ARM

Étudiante :

Laura Binacchi

Lieu de stage :

EVS Broadcast EquipmentRue du Bois Saint-Jean 13, 4102 Ougrée

Maître de stage :

Bernard ThilmantSoftware Engineer

Épreuve intégrée présentée pour l'obtention du diplôme de BACHELIER.E EN INFORMATIQUE ET SYSTÈMES FINALITÉ : INFORMATIQUE INDUSTRIELLE

Table des matières

	Introduction	1			
1	EVS Broadcast Equipment 1.1 Présentation d'EVS et du département R&D	2 2			
	1.2 Le serveur XT	2			
2	L'encodage audionumérique : généralités	4			
	2.1 Le son	4			
	2.2 La numérisation d'un signal	4			
3	Les codecs audio	5			
	3.1 Définition d'un codec	5			
	3.2 Les codecs MPEG	5			
	3.3 Les modèles psychoacoustiques	6			
4	Le codec AAC	8			
	4.1 Fonctionnement de l'encodeur AAC	8			
	4.2 Le bloc MDCT	8			
5	Environnement de développement				
6	Algorithmes MDCT de référence	10			
Ŭ	6.1 Description mathématique	10			
	6.2 Implémentations des MDCT de référence en <i>floating point</i> et <i>fixed point</i>	10			
	6.3 Validation	11			
7	Algorithme MDCT basé sur la FFT	15			
	7.1 Optimisations attendues	15			
	7.2 Implémentation de la MDCT basée sur la FFT de la librairie FFTW3	15			
	7.3 Validation	15			
8	Intégration de la librairie Ne10	18			
	8.1 Choix de la librairie	18			
	8.2 Implémentation de la MDCT basée sur la FFT Ne10 en float 32	18			
	8.3 Validation	19			
	8.4 Performances	20			
9	Algorithme MDCT en arithmétique fixed point	21			
	9.1 Arithmétique fixed point	21			
	9.2 Implémentation de la MDCT basée sur la FFT Ne10 en arithmétique <i>fixed point</i>	22			
	9.2.1 Utilisation de la FFT Ne10 en int 32	22			
	9.2.2 Initialisation des <i>twiddle factors</i>	23 23			
	9.2.3 Validation				
	9.4 Performances				

10	Optimisations à l'architecture ARM 10.1 Spécificités de l'architecture ARMv7	
11	Analyse des résultats	28
	11.1 Validation des données	28
	11.2 Gain en performance	28
	11.3 Perte de précision	
12	Améliorations possibles	30
	Conclusion	31
	Références	31

Table des figures

1	Logo de la société EVS Broadcast Equipment[1]	2
2	Vues avant et arrière (en configuration IP) de l'XT-VIA[2]	3
3	Vue simplifiée d'un codec MPEG basé sur un modèle psychoacoustique[3]	5
4	Effets de masque dans le domaine fréquentiel[4]	7
5	Signal sinusoïdal à 440 Hz codé en floating point (float et double)	12
6	Spectres de fréquences générés par les MDCT de référence en floating point	12
7	Signal sinusoïdal à 440 Hz codé en fixed point (Q15)	13
8	Spectre de fréquences généré par les MDCT de référence en fixed point	14
9		16
10		17
11		20
12	Comparaison des spectres des fréquences produits par la MDCT Ne10 i32 plain C et par la MDCT de	
	référence en integer	25
13		27

Remerciements

Introduction

Développement d'une solution de software embarqué sur processeur ARM pour encodage audio AAC optimisé aux applications d'EVS :

- Prise de connaissance de l'encodage AAC et de l'environnement EVS qui utilise ce type de format;
- Prise de connaissance des résultats des optimisations possibles du modèle psycho-acoustique développé par EVS;
- Développement du code en C ou Assembler pour l'encodage AAC sur plateforme ARM;
- Test du système et documentation de son implémentation.

1 EVS Broadcast Equipment

1.1 Présentation d'EVS et du département R&D

Mon stage s'est déroulé au sein de la société EVS Broadcast Equipment dont la figure 1 représente le logo. EVS est une entreprise d'origine liégeoise devenue internationale. Fondée en 1994 par Pierre L'Hoest, Laurent Minguet et Michel Counson, EVS compte aujourd'hui plus de 600 employés dans plus de 20 bureaux à travers le monde mais son siège principal se situe toujours à Liège.



FIGURE 1 – Logo de la société EVS Broadcast Equipment[1]

EVS est devenu leader dans le monde du broadcast avec ses serveurs permettant l'accès et la diffusion instantanée des données audiovisuelles enregistrées sur ses serveurs. L'entreprise est également célèbre pour ses ralentis instantanés. Ces technologies sont utilisées pour la production live des plus importants événements sportifs dans le monde : le matériel EVS est notamment utilisé pour la retransmission des Jeux Olympiques depuis 1998.

Plus de 50% des employés d'EVS travaillent en recherche et développement afin de répondre au marché du broadcast en constante évolution. Outre ses solutions techniques innovantes, EVS se différencie de ses concurrents par la proximité entretenue avec les clients en leur proposant des solutions à l'écoute de leurs besoins et en leur offrant un service de support de qualité.

C'est en R&D, dans l'équipe Hardware-Firmware, que s'est déroulé mon stage. Sous la direction de Justin Mannesberg, cette équipe se compose d'une vingtaine d'employés spécialisés en développement embarqué et en développement FPGA. La situation particulière dans laquelle s'est déroulé mon stage, en pleine pandémie de Covid et alors que tous les employés étaient confinés, ne m'a pas permis d'interagir avec beaucoup de membres de l'équipe et ni de pouvoir observer leur travail. Bernard Thilmant (Software Engineer dans l'équipe Hardware-Firmware) a cependant réussi à m'apporter le soutien nécessaire à la bonne réalisation de mon stage : il m'a permis de m'initier au C++, m'a aidée à ne pas me perdre dans les concepts parfois complexes de l'encodage audio et m'a aidée à apporter la rigueur scientifique nécessaire à la réalisation de mon travail. J'ai également pu bénéficier de l'expertise technique de Frédéric Lefranc (Principal Embedded System Architect dans l'équipe Hardware-Firmware) ainsi que du suivi de Justin Mannesberg (Manager de l'équipe Hardware-Firmware).

1.2 Le serveur XT

EVS développe et commercialise de nombreux produits allant des serveurs de production aux interfaces permettant d'exploiter des données audiovisuelles ou de monitorer des systèmes de production[2]. Le serveur de production live XT est un des produits emblématiques d'EVS. Il permet de stocker de grandes quantités de données audiovisuelles et d'y accéder en temps réel afin de répondre aux besoins de la production en live. Par exemple, la remote LSM (*Live Slow Motion* permet d'accéder aux contenus des serveurs XT afin de créer les ralentis pour lesquels EVS est célèbre dans le monde.





FIGURE 2 – Vues avant et arrière (en configuration IP) de l'XT-VIA[2]

Le serveur XT a connu plusieurs versions : XT, XT2, XT2+, XT3 et enfin l'XT-VIA. L'XT-VIA (cf figure 2), la plus récente version du serveur XT, en quelques informations clés[2] :

- offre un espace de stockage de 18 à 54 TB, soit plus de 130h d'enregistrement en UHD-4K;
- dispose de 2 à plus de 16 canaux selon le format choisi : 2 canaux en UHD-8K (4320p), 6 canaux en UHD-4K (2160p) et plus de 16 canaux en FHD and HD (720p, 1080i, 1080p);
- permet une configuration hybride de ses entrées et sorties en IP (10G Ethernet SFP+, 100G en option, ST2022-6, ST2022-7, ST2022-8, ST2110, NMOS IS-04, IS-05, EMBER+, PTP) ou SDI (1.5G-SDI, 3G-SDI et 12G-SDI);
- supporte de nombreux formats d'encodage vidéo : UHD-4K (XAVC-Intra et DNxHR), HD/FHD (XAVC-I, AVC-I, DNxHD et ProRes), PROXY (MJPEG et H264);
- peut enregistrer 192 canaux audio non compressés et supporte les standards AES et MADI;
- offre de nombreuses possibilités de connexion avec du matériel EVS ou non.

C'est pour la dernière génération du serveur XT, l'XT-VIA, que le codec AAC est développé. La compression avec perte de données de ce codec permet d'optimiser l'espace occupé par les données audio sans en altérer la qualité perçue. Outre la qualité audio, les performances de l'encodage sont importantes à prendre en compte pour permettre l'enregistrement de plusieurs canaux en parallèle tout en conservant un traitement de l'information qui tienne le temps réel. L'optimisation des performances doit tenir compte de l'architecture de l'XT-VIA : l'architecture ARM Neon remplace l'architecture Intel x86 de ses prédécesseurs avec des différences importantes dans les fonctions intrinsèques.

- 2 L'encodage audionumérique : généralités
- 2.1 Le son
- 2.2 La numérisation d'un signal

3 Les codecs audio

3.1 Définition d'un codec

Un codec est un procédé logiciel composé d'un encodeur (*coder*) et d'un décodeur (*decoder*)[5]. Un codec audio permet donc, d'une part, de coder un signal audio dans un flux de données numériques et, d'autre part, de décoder ces données afin de restituer le signal audio.

Les codecs sont dits avec perte (*lossy*) ou sans perte (*lossless*). Le PCM est par exemple un codec sans perte puisqu'il encode la totalité des informations sonores dans la bande de fréquences humainement audible. Ce type de codec permet de conserver la qualité de l'audio mais nécessite en contrepartie un espace de stockage conséquent, même avec une compression des données.

Afin de réduire l'espace de stockage nécessaire, les codecs avec perte permettent de supprimer une partie des données audio. C'est le cas des codecs définis par les normes MPEG dont fait partie le codec AAC.

3.2 Les codecs MPEG

MPEG (*Moving Picture Experts Group*) désigne une alliance de différents groupes de travail définissant des normes d'encodage, de compression et décompression et de transmission de média audio, vidéo et graphiques[6]. Le groupe est actif depuis 1988 et a produit depuis de nombreuses normes.

Les codecs audio qui implémentent les normes MPEG ont pour point commun d'être des codecs avec perte de données basés sur un modèle psychoacoustique. Le premier est le MP3, défini par la norme MPEG-1 Layer-3 ISO/IEC 11172-3 :1993. Le codec AAC est conçu en 1997 pour remplacer le MP3. Il est défini par les normes MPEG-2 partie 7 ISO/IEC 13818-7 :2006[7] et MPEG-4 partie 3 ISO/IEC 14496-3 :2019[8].

Les normes MPEG définissent les grandes lignes de l'encodage et du décodage et le format du conteneur mais pas l'implémentation du codec qui peut de ce fait être plus ou moins performant. Les codecs MPEG sont typiquement composés des blocs suivants :

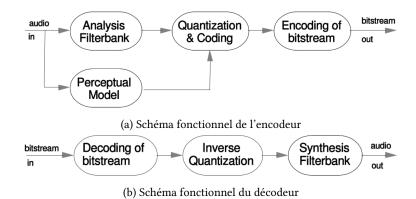


FIGURE 3 – Vue simplifiée d'un codec MPEG basé sur un modèle psychoacoustique[3]

L'encodeur est composé des blocs suivants :

filter bank la banque de filtres décompose le signal temporel d'entrée en différentes composantes fréquentielles

perceptual model le modèle psychoacoustique utilise le signal temporel et/ou sa décomposition fréquentielle pour éliminer les données audio dont l'absence ne nuira pas à la qualité perçue à l'écoute ()

quantization and coding la quantification attribue une valeur numérique aux données du spectre de fréquences : elles sont typiquement codées avec une méthode entropique qui peut être optimisée avec le modèle psychoacoustique

encoding of bitstream les données sont formatées en un flux contenant typiquement le spectre de fréquences codé et des informations supplémentaires permettant l'encodage

Le décodeur a un fonctionnement inverse : le flux de données est décodé (**decoding of bitstream**), les composantes fréquentielles du signal sont retrouvées par l'opération inverse à la quantification (**inverse quantization**) et ces sousbandes fréquentielles sont finalement rassemblées pour reconstituer le signal temporel (**synthesis filter bank**).

Le fonctionnement du décodeur ne sera pas plus développé dans ce travail car le bloc MDCT fait partie de la banque de filtres de l'encodeur. Le fonctionnement spécifique de l'encodeur AAC sera par contre détaillé dans la section 4.

3.3 Les modèles psychoacoustiques

Le section précédente a défini les codecs MPEG comme étant basés sur un modèle psychoacoustique. La psychoacoustique est une branche de la psychophysique qui étudie la manière dont l'oreille humaine perçoit le son[9]. Cette discipline permet d'améliorer la compression d'un signal audio en éliminant les sons qui sont captés par un microphone mais qui ne peuvent pas être perçus par l'oreille humaine et les avancées dans cette discipline permettent de développer des encodeurs audio de plus en plus performants. Les codecs basés sur un modèle psychoacoustique sont toujours des codecs avec perte puisqu'une partie des informations auditives sera définitivement perdue, ce qui ne nuit pour autant pas à la qualité perçue du son.

L'encodage audionumérique tient déjà compte des seuils de fréquences humainement audibles pour limiter les données audio enregistrées : nous l'avons vu dans la section 2.2, aucun son n'est perçu en-deça de 20 Hz ou au-delà de 20 kHz. La psychoacoustique permet de mieux dessiner la limite entre ce qui est humainement audible ou non afin d'éliminer un maximum des informations non pertinentes et ainsi augmenter le facteur de compression des données : le facteur de compression des codecs MPEG est environ 15 fois supérieur à celui du CD[4].

Les effets de masque sont au centre des différents modèles psychoacoustiques utilisés pour la compression audio. L'enjeu afin d'obtenir le meilleur taux de compression est de calculer le plus finement possible les seuils de masquage, i.e. la limite entre les informations pertinentes et celles qui peuvent être éliminées. Les effets de masques dans le domaine fréquentiel (*spectral masking effects*) sont parmi les plus utilisés mais il en existe d'autres, e.g. dans le domaine temporel. La figure suivante représente différents effets de masque du domaine fréquentiel :

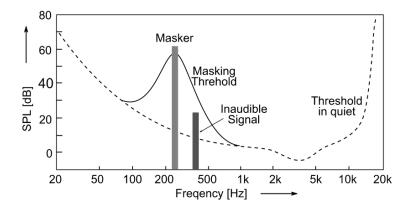


FIGURE 4 – Effets de masque dans le domaine fréquentiel[4]

- 4 Le codec AAC
- 4.1 Fonctionnement de l'encodeur AAC
- 4.2 Le bloc MDCT

5 Environnement de développement

6 Algorithmes MDCT de référence

La première étape de ce travail consiste à développer des algorithmes de référence afin de valider les différentes MDCT implémentées par la suite. Ces algorithmes de référence sont développés en algorithmique flottante sur base de la formule mathématique de la MDCT. Ils permettent de générer des spectres de fréquences en *float* ou en *integer* afin de valider les données de sortie des MDCT optimisées.

6.1 Description mathématique

La transformation effectuée par la MDCT est donnée par l'équation suivante[10] :

$$X_k = \sum_{n=0}^{2N-1} x_n \cos \left[\frac{\pi}{N} \left(N + \frac{1}{2} + \frac{N}{2} \right) \left(k + \frac{1}{2} \right) \right]$$

 X_k avec $k \in [0, N[$ pour une fenêtre d'entrée de 2N échantillons

 x_n avec $n \in [0, 2N[$: la fenêtre d'entrée

 $F: \mathbb{R}^{2N} \to \mathbb{R}^N$ la MDCT est une fonction linéaire qui pour 2N nombres réels en entrée produit N nombres réels en sortie

À cette équation s'ajoute le facteur d'échelle $\frac{2}{\sqrt{2N}}$.

La MDCT a été implémentée avec une fenêtre d'entrée de 2N = 1024 échantillons. Le bloc de sortie, i.e. le spectre de fréquences de la fenêtre d'entrée, aura donc une taille de 512. Ces valeurs, utilisées à de très nombreux endroits du code, sont rassemblées dans le header mdct_constants.h présenté dans l'annexe B. Ce fichier contient également d'autres valeurs précalculées sur base de la taille de la fenêtre d'entrée.

La section suivante présente deux implémentations simples de cette formule. Ces implémentations ne pourraient pas être utilisées sans avoir été optimisées car elles seraient beaucoup trop lentes pour un codec qui doit tenir le temps réel sur plusieurs canaux. La complexité de l'implémentation de cette formule est de $O(N^2)$ opérations (où N est la taille de la fenêtre d'entrée). Cette complexité peut être ramenée à $O(N\log N)$ opérations par une factorisation récursive. La complexité peut également être diminuée en se basant sur une autre transformation, e.g. une DFT (Discrete Fourier Transorm) ou une autre DCT (Discrete Cosine Transform) : la complexité sera alors de O(N) opérations de pre- et post-processing en plus de la complexité de la DFT ou de la DCT choisie[10]. C'est cette dernière option qui a été retenue pour ce travail.

6.2 Implémentations des MDCT de référence en floating point et fixed point

La formule mathématique de la MDCT a été implémentée très simplement en algorithmique flottante avec la possibilité d'obtenir le spectre de fréquences codé en *float*, *double* ou *int32*. L'objectif de ces implémentations est de pouvoir valider les spectres de fréquences calculés par les implémentations optimisées de la MDCT. Les MDCT de référence serviront également à mesurer la précision des MDCT optimisées.

La première implémentation de l'équation de la MDCT est présentée dans l'**annexe C.1**. La fonction développée permet de faire ses calculs et d'obtenir un résultat aussi bien en *float* (32 bits) qu'en *double* (64 bits) grâce à l'utilisation d'un *template*. Le signal temporel a la même précision (*float* ou *double*) que le spectre généré.

La seconde fonction de référence est présentée dans l'annexe C.2. Elle permettra de vérifier les résultats des implémentations optimisées en *fixed point*. Tous les calculs ne sont pas fait en algorithmique entière : la fonction fait les mêmes calculs que la fonction de référence en algorithmique flottante (uniquement en *double* cette fois pour garder le plus de précision possible) et transtype le résultat final dans un *integer* de 32 bits qui correspond à une notation Qx.15 signée.

6.3 Validation

Les MDCT de référence sont validées en générant le spectre de fréquences d'un signal connu pour pouvoir observer que celui-ci corresponde bien à ce qui est attendu. Tout au long de ce travail, les MDCT ont été validées avec divers signaux en entrée : des signaux à une ou plusieurs fréquences connues ou des données aléatoires. La section 11.1 consacrée au protocole de validation donne plus de détails sur la génération des spectres de fréquences produits par les MDCT et leur interprétation.

Afin de faciliter la lecture des résultats et les comparaisons, ce travail présentera principalement des tests effectués avec en entrée un signal à 440 Hz. L'annexe D présente les codes permettant de générer des signaux sinusoïdaux. Les signaux sinusoïdaux sont produits en *floating point* (annexe D.1) ou en *fixed point* (annexe D.2). Le signal est paramétrable :

- en taille ou nombre d'échantillons : la fenêtre d'entrée de la MDCT sera toujours de 1024 échantillons ;
- en amplitude : paramètre utilisé pour limiter le signal un un certain range de valeurs ;
- en fréquence : la fréquence des exemples de résultats donnés dans ce travail sera le plus souvent de 440 Hz mais les MDCT ont été testées avec de nombreux autres signaux ;
- en déphasage : ce paramètre n'a pas été utilisé;
- et en fréquence d'échantillonnage toujours à 48 kHz.

La headroom est l'espace réservé aux valeurs limites du signal : le signal réel est clippé et ne couvre pas l'ensemble des valeurs possibles. Dans ce travail, la range du signal est toujours comprise entre -0.9 et 0.9, que le signal soit codé en floating point ou en fixed point. Ce fait est moins important pour les algorithmes travaillant en floating point mais il sera essentiel pour la mise à échelle des données en représentation fixed point (section 9).

Les signaux codés en *float* ou en *double* serviront à valider les implémenations intermédiaires de la MDCT. L'objectif reste cependant de développer une MDCT capable de traiter des données entières sans transtypage. Le signal en *integer* servira à valider les dernières itérations de la MDCT. Ce signal est codé en 16 bits (représentation Q15 signée) afin de correspondre aux données réelles qui seront reçues par l'algorithme.

La figure 5 offre une représentation graphique des signaux sinusoïdaux en *floating point* utilisés pour tester les MDCT en *floating point* :

- les deux signaux sont équivalents : le signal généré en *float* (en pointillés) se superpose parfaitement au signal généré en *double* ;
- la période du signal est de 2.3 ms correspondant à la fréquence de 440 Hz attendue;
- les valeurs du signal sont comprises entre -0.9 et 0.9 pour respecter une headroom.




Figure 5 – Signal sinusoïdal à 440 Hz codé en floating point (float et double)




FIGURE 6 – Spectres de fréquences générés par les MDCT de référence en floating point

Les MDCT de référence en *floating point* prenant en entrée ces signaux sinusoïdaux à 440 Hz génèrent les spectres de fréquences présentés à la figure 6 :

- les deux MDCT génèrent le même spectre : le spectre généré par l'agorithme en *float* (en pointillés) se superpose parfaitement à celui généré en *double* ;
- la représentation graphique des spectres de fréquences met bien en évidence une composante fréquentielle principale aux alentours de 440 Hz;

Le résultat obtenu est déjà satisfaisant puique la fréquence mise en évidence par le spectre est bien celle du signal d'entrée. Cependant, l'impléméntation d'une fonction de fenêtre appliquée au signal d'entrée permettrait d'améliorer encore le spectre de fréquences généré par la MDCT. La section 12 consacrée aux améliorations possibles de ce travail revient sur cette fonction de fenêtre.

Le signal sinusoïdal en fixed point utilisé pour la validation des MDCT fixed point est représenté par la figure 7 :

- le signal prend la même forme que ceux en *floating point* (figure 5);
- la période du signal de 2.3 ms correspond à la fréquence de 440 Hz attendue;
- le signal varie entre 29491 et -29491, valeurs qui corespondent aux valeurs limites du signal en *floating point* mises à échelle pour une représentation *fixed point* Q15.




FIGURE 7 – Signal sinusoïdal à 440 Hz codé en fixed point (Q15)

La représentation graphique du spectre de fréquences généré par la MDCT de référence en *fixed point* à partir du signal à 440 Hz est présentée par la figure 8 :

• le spectre prend la même forme que le spectre de fréquence généré par les MDCT en *floating point* (figure 8);

- le spectre met bien en évidence une composante fréquentielle principale aux alentours de 440 Hz;
- les valeurs des composantes fréquentielles sont beaucoup plus grandes que celles du spectre en *floating point* puisqu'elles sont mise à échelle Q15.




FIGURE 8 – Spectre de fréquences généré par les MDCT de référence en fixed point

7 Algorithme MDCT basé sur la FFT

7.1 Optimisations attendues

Choix de l'optimisation de la MDCT basé sur sur une DCT : la FFT -> complexité de O (N log N) (N taille de la fenetre) + O(N) opérations de pré et de post processing.

But : utiliser une FFT déjà optimisée pour n'avoir à optimiser "que" les opérations de pré et de post processing Exemple trouvé sur le site DSP related -> Annexe ? Citation ?

7.2 Implémentation de la MDCT basée sur la FFT de la librairie FFTW3

Code développé à partir de cet exemple en annexe. Il est basé sur la librairie FFTW3 qu'on ne peut pas garder car ne permet pas de travailler en integer -> sera amené à être retravaillé.

Explications des paramètres du code :

- fenêtre de 1024
- pre-twiddle -> 256
- FFT => FFT avec une fenêtre d'entrée réduite et donc une complexité réduite
- post-twiddle -> 512

7.3 Validation

Validé avec un single tone signal + l'algo de référence.

Présentation des résultats sous forme de données brutes ou de graphique.




Figure 9

Code d'exemple qui teste l'algo de référence et l'algo FFTW3 avec les mêmes données d'entrée pour comparaison. (on fait la différence pour la précision? ce n'est peut être pas pertinent de la faire déjà)

Présentation des résultats sous forme de données brutes ou de graphiques.

A ce niveau, pour valider, j'ai aussi essayé de faire la IMDCT mais d $\hat{\mathbf{u}}$ à l'overlap, sur une seule fenetre, on ne sait pas reconstruire le signal -> pas possible de valider comme ça




Figure 10

8 Intégration de la librairie Ne10

8.1 Choix de la librairie

La librairie *FFTW3* utilisée pour l'itération précédente de la MDCT ne propose pas de *FFT* en algorithmique entière. Le passage à une autre librairie était donc nécessaire et le choix s'est porté sur la librairie *Ne10* qui propose différentes *FFT* en *fixed point*.

Le projet *Ne10* propose toute une série de fonctions mathématiques et physiques de base ainsi que des fonctions de traitement de signal et de traitement d'image. La librairie est spécifiquement développée pour les architectures ARM possédant les opérations SIMD Neon (ARMv7 et ARMv8-A)[11].

Ne10 propose à la fois des fonctions développées en plain C et des fonctions optimisées avec les instructions SIMD Neon : les deux types de fonctions seront utilisées pour développer une MDCT optimisée et pour conserver une MDCT de référence en plain C. Maintenir une MDCT plain C permettra d'avoir une référence pour la mesure des performances de l'algorithme fixed point mais pourrait aussi s'avérer utile pour une utilisation de l'encodeur AAC sur une architecture ARM ne possédant pas les instructions Neon.

L'utilisation de la librairie *Ne10* est soumise à la licence *3-Clause BSD*, license permissive qui permet un usage commercial des produits intégrant la librairie et qui ne contraint pas à en distribuer le code source[12].

8.2 Implémentation de la MDCT basée sur la FFT Ne10 en float 32

La librairie Ne10 s'installe simplement en suivant les instructions données par la documentation : clone du projet GitHub, run du CMake et build du projet[11]. La librairie ne peut cependant être installée que sur une plateforme Linux, Android ou iOS reposant sur une architecture ARM. À partir de ce moment, il n'est donc plus possible de maintenir une implémentation de référence de la MDCT pour une architecture Intel.

Ne10 propose des algorithmes de FFT real to complex et complex to complex en floating point (32 bits) ou en integer (32 bits et 16 bits). L'objectif est évidemment de passer toute la MDCT en integer mais pour un premier test de la librairie, l'algorithme de la section précédente a tout d'abord été repris en remplaçant la FFT de FFTW3 par la fonction ne10_fft_c2c_1d_float32_neon de Ne10: FFT en complex to complex en float 32, i.e. l'entrée et la sortie de la FFT sont représentées sous forme de tableaux de nombres complexes codés en float sur 32 bits.

L'annexe ?? présente le code de cette implémentation. L'annexe ?? montre que ce code est construit sur le même modèle que le code utilisant la librairie *FFTW3*. La classe contient la configuration de la FFT et les tableaux contenant les données d'entrée, les données de sortie et les facteurs de twiddling. La classe définit trois fonctions publiques : le constructeur, le destructeur et la fonction MDCT.

L'annexe ?? montre l'initialisation de la MDCT dans le constructeur de la classe. Le constructeur initialise les tableaux de facteurs de twiddling de le même manière que l'algorithme basé sur la FFT de FFTW3. La configuration de la FFT de Ne10 se fait conformément au code d'exemple donné par la documentation de la librairie[11] avec en paramètre la taille de la FFT qui correspond au quart de la taille de la fenêtre d'entrée.

Le destructeur présenté à l'annexe ?? permet de libérer la mémoire allouée pour la FFT en appelant la fonction adéquate de la librairie Ne10.

La fonction MDCT présentée dans l'annexe ??, comme pour l'algorithme précédent :

- effectue les opérations de *pre-processing* ou *pre-twiddling* : ce sont les mêmes que celle de la MDCT *FFTW3* en arithmétique *floating point* sur 32 bits;
- appelle l'algorithme de FFT : la FFT de Ne10 prend en paramètres les tableaux contenant les données d'entrée et de sortie, la configuration de la FFT et un integer à 0 pour réaliser la FFT ou à 1 pour réaliser l'opération inverse :
- effectue les opérations de *post-processing* ou *post-twiddling* : ici aussi les mêmes que celles de la MDCT *FFTW3* en arithmétique *floating point* sur 32 bits.

L'algorithme développé ici ne diffère donc pas de l'algorithme présenté à la section précédente. Son développement est trivial mais il permet de tester et de valider le fonctionnement de la librairie *Ne10*.

8.3 Validation

L'utilisation de la librairie *Ne10* est validée par comparaison du spectre de fréquences qu'elle génère avec les spectres générés par la MDCT de référence en *double* et par la MDCT basée sur *FFTW3* également en *double*. Les MDCT sont appelées en *double* pour plus de précision. La comparaison aurait pu se faire sur base de tous les algorithmes de MDCT en *float* sur 32 bits mais le choix qui a été fait ici permet en plus de vérifier que la perte de précision entre le *float* et le *double* soit acceptable.

Le code source permettant de comparer les trois MDCT en *floating point* est présenté à l'annexe ??. Il sera expliqué en détail dans la section 11.1 consacrée à la validation des données des MDCT. Compilé avec les commandes CMake de l'annexe ??, le code produit un exécutable permettant de comparer les spectres de fréquence produits par les trois MDCT *floating point* en les affichant en console.




FIGURE 11

En redirigeant les données sorties en console vers un fichier texte, il est possible d'exploiter ces données sous forme de graphique. (voir figure ??) TODO : explication du graphique

TODO : présentation de la précision

8.4 Performances

Une fois l'utilisation de la librairie Ne10 validée, Mesure de la différence de performance entre différentes FFT : code en annexe

FFT Ne10 f32 plain C average run time : 5632.06 ns standard deviation : 4.38439e-09 ns FFT Ne10 f32 Neon average run time : 3115.18 ns standard deviation : 2.81769e-06 ns FFT Ne10 i32 plain C average run time : 10723.1 ns standard deviation : 1.77145e-06 ns

FFT Ne10 i32 Neon average run time : 3455.78 ns standard deviation : 5.35823e-07 ns

FFT Ne10 i16 plain C average run time : 9557.52 ns standard deviation : 1.69145e-07 ns

FFT Ne10 i16 Neon

9 Algorithme MDCT en arithmétique fixed point

Le passage d'une arithmétique flottante à une arithmétique entière est une des optimisations envisagées par l'analyse préalable à ce travail. Le bénéfice attendu est double : l'arithmétique entière est généralement plus rapide et un bloc MDCT en arithmétique entière serait mieux intégré à l'ensemble de l'encodeur.

La première de ces attentes n'a pas pu être rencontrée. En effet, l'architecture ARMv7 du Raspberry supporte de nombreuses instructions en *floating point* sur 32 bits[13]. Or, plusieurs instructions *fixed point* sont souvent nécessaires pour remplacer une seule instruction en *floating point*, e.g. une multiplication en float est remplacée au minimum par une multiplication et une rotation de bits pour que le produit tienne sur le même nombre de bits que les nombres multipliés. Plutôt que de gagner en temps d'exécution, le passage en *fixed point* a ralenti la MDCT.

Cependant, le passage en *fixed point* permet d'économiser un transtypage du *integer* vers le *float* en entrée de la MDCT et inversement en sortie. Avec un temps d'exécution au moins équivalent en *fixed point* qu'en *floating point*, le passage en *fixed point* permettrait donc tout de même d'améliorer les performances de l'ensemble de l'encodeur AAC.

Enfin, les données reçues à l'entrée de la MDCT sont codées en *integer* sur 16 bits alors que les *float* sont codés au minimum sur 32 bits. Garder le maximum de données et d'opérations en 16 bits permettrait de gagner en performance au moment de l'utilisation des opérations SIMD.

9.1 Arithmétique fixed point

La représentation *fixed point* est une alternative au *float* pour le codage des nombres décimaux[14]. Le principe est de réserver un certain nombres de bits pour coder la partie entière et un autre nombre de bits pour coder la partie décimale du nombre. Ce travail utilise deux notations pour la représentation en *fixed point*, toujours signée :

- *Qm* où *m* est le nombre de bits réservés aux décimales, e.g. une notation Q15 sur 16 bits permet de représenter un nombre signé ne contenant que des décimales et pas de partie entière puisqu'un bit est réservé pour le signe ;
- *Qx.y* où *x* est le nombre de bits réservés à la partie entière et *y* le nombre de bits réservés à la partie décimale, e.g. une notation Q1.15 équivaut à une notation Q15 sur 16 bits.

Pour passer la MDCT en algorithmique *fixed point*, il faut tout d'abord prêter attention à choisir la représentation adéquate. Par exemple, les données d'entrée de la MDCT sont comprises entre 0.9 et -0.9. Elles peuvent donc être représentées en Q15. Si elles avaient été comprises ente 1 et -1, la conversion à une représentation Q15 aurait produit un dépassement sur l'une des valeurs limites et par conséquent une perte d'information.

Des dépassements peuvent également se produire lors des opérations arithmétiques :

- une **addition** ou une **soustraction** peut causer un dépassement d'un bit, e.g. la somme d'un nombre sur 32 bits et d'un nombre sur 16 bits nécessite potentiellement 33 bits pour être codée;
- le résultat d'une **multiplication** ou d'une **division** peut devoir être codé sur un nombre de bits équivalent à la somme des nombres de bits composants les deux nombres multipliés ou divisés, e.g. le produit d'un nombre de 16 bits multiplié par un nombre de 32 bits nécessite potentiellement 48 bits pour être codé.

Ces dépassements sont théoriques. En fonction des données réelles à traiter, il est possible de ne pas respecter à la lettre les règles énoncées plus haut. C'est le cas par exemple avec les facteurs de *twiddling* dont on sait qu'il valent au maximum un quart de la valeur d'un sinus ou d'un cosinus et qui sont codés en Q15 : il est alors certain que l'addition de deux de ces nombres ne causera pas de dépassement.

Là où l'implémentation en *floating point* était triviale, puisqu'elle demandait simplement de reprendre le code d'exemple fourni et de l'adapter à l'utilisation de la librairie *Ne10*, l'implémentation en *fixed point* devient plus complexe : il faut prêter attention à coder les nombres dans les bonnes ranges et implémenter les différentes opérations arithmétiques de sorte à ne pas causer de dépassements.

9.2 Implémentation de la MDCT basée sur la FFT Ne10 en arithmétique *fixed point*

L'annexe J présente l'implémentation de la MDCT *Ne10 fixed point* en *plain C*. La classe mdct_ne10_i32_c a la même structure que l'implémentation en *floating point*. Le header présenté dans l'annexe J.1 montre que seul le type des données a changé :

- La configuration et les tableaux d'entrée et de sortie de la FFT sont définis avec les types int32, et non plus float32, de la librairie Ne10;
- Le tableau de facteurs de twiddling passe du float au int16_t;
- La fonction MDCT prend en paramètres un signal temporel en int16_t et renvoie un spectre en int32_t au lieu des tableaux de float.

9.2.1 Utilisation de la FFT Ne10 en int 32

L'utilisation de la librairie Ne10 en integer est très peu différente de son utilisation en float :

- La configuration est initialisée dans le constructeur de la classe mdct_ne10_i32_c (annexe J.2) en complex to complex en integer 32 avec en paramètre la taille de la fenêtre de la FFT réduite à un quart de la taille de la fenêtre d'entrée.
- L'espace alloué à la configuration est libéré dans le destructeur de la classe mdct_ne10_i32_c (annexe J.3) avec la fonction appropriée de la librairie *Ne10*;
- La fonction de FFT est appelée avec en paramètres le tableau contenant les données d'entrée, le tableau dans lequel sera calculé le résultat de la FFT, la configuration préalablement initialisée, un *integer* qui indique à la fonction de réaliser la FFT et non son opération inverse et, en plus de la FFT en *float*, un facteur de mise à échelle mis ici à 0.

Il est à noter que l'initialisation du facteur de mise à échelle de la fonction de FFT n'est pas documentée dans la librairie *Ne10*. L'effet de ce facteur sur la FFT n'est pas non plus indiqué. J'ai initialisé ce facteur à 0 après avoir testé la FFT de *Ne10* dans le but d'obtenir les mêmes valeurs qu'en *float* mises à une échelle Q15.

La documentation incomplète de la librairie a été une des difficultés de ce travail. En dehors des quelques codes d'exemples disponibles, il est très compliqué de savoir quelles données sont attendues et sont produites par les fonctions de *Ne10*. Il est également très difficile de trouver des ressources externes sur l'utilisation de *Ne10*.

Le manque de documentation est également ce qui a empêché l'utilisation de la FFT en *int16* plutôt qu'en *int32*. Des opérations en 16 bits pour tout le bloc MDCT auraient été plus performantes. Malheureusement, si la documentation de *Ne10* dit bien travailler en Q15 pour du 16 bits et en Q31 pour du 32 bits, elle ne dit pas quelle *headroom* prévoir, quelles *ranges* de valeurs sont acceptées, si les opérations saturent ou non, etc. En testant la FFT 16 bits avec des données codées en Q15, trop de valeurs fausses étaient produites par la FFT. L'utilisation du facteur de mise à échelle n'a pas non plus permis d'obtenir de résultats satisfaisant.

Pour ne pas produire de dépassement dans la fonction de FFT, il a fallu prévoir 8 bits de *headroom* pour la FFT. Sur des données codées sur 16 bits, cela signifie qu'il ne resterait plus que 8 bits de données utiles pour le signal, dont 1 bit pour le signe. Cette perte de précision trop importante a forcé l'utilisation de la FFT en 32 bits.

9.2.2 Initialisation des twiddle factors

Le tableau de facteurs de twiddle est initialisé dans le constructeur de la classe mdct_ne10_i32_c (annexe J.2). Ses valeurs sont calculées en *double* puis converties en *integer* (représentation Q15).

Il aurait été posible de convertir les opérations d'initialisation en *fixed point* mais l'optimisation du constructeur n'est pas nécessaire. En effet, puisque la taille de fenêtre d'entrée ne varie pas, l'appel de l'initialisation ne sera fait qu'une fois et la MDCT est ensuite appelée en boucle avec les mêmes facteurs de *twiddling*.

9.2.3 Opérations de pre-twiddling et de post-twiddling

L'essentiel du tavail pour cette implémentation a été le passage des opérations de *pre*- et de *post-processing* en arithmétique *fixed point*. Le résultat de ce travail est présenté dans l'**annexe J.3** qui présente la fonction MDCT basée sur la FFT de *Ne10* en *plain C*.

Les opérations de *pre-twiddling* transforment le signal temporel et les facteurs de *twiddling*, tous deux en représentation Q15, en un nombre en représentation Q1.23 sur 32 bits à donner en entrée de la FFT de *Ne10* en *int32*. La représentation Q1.23 est celle qui permet de garder le maximum de précision tout en s'assurant de ne pas produire de dépassement dans la FFT en gardant 8 bits de *headroom*.

Le post-twiddling récupère les données en Q9.23 produites par la FFT de Ne10 : la précision de 23 décimales donnée en entrée, le bit de signe et les 8 bits de headroom. En combinaison avec les facteurs de twiddling codés en Q15, elles sont transformées en un spectre de fréquences codé en Q9.15 sur 32 bits.

Les opérations de *pre-processing* suivent toujours le même schéma : les parties réelles ou imaginaires des données d'entrée de la FFT sont la somme de deux produits d'un facteur de *twiddling* et de la somme de deux échantillons du signal temporel. Voici en exemple la transformation de la première opération de l'arithmétique *floating point* vers l'arithmétique *fixed point* :

```
fft\_in[i/2].r = r0 * c + i0 * s; devient fft\_in[i/2].r = (((r0 * c) + 64) >> 7) + (((i0 * s) + 64) >> 7); où r0 = time\_signal[MDCT_M32 - 1 - i] + time\_signal[MDCT_M32 + i]; et i0 = time\_signal[MDCT_M2 + i] - time\_signal[MDCT_M2 - 1 - i];
```

- **r0** est la somme de deux échantillons du signal temporel codés en Q1.15 : il correspond donc à une notation **Q2.15** ici codée sur 32 bits plutôt que de perdre un bit de précision pour garder la valeur sur 16 bits ;
- **c** twiddle factor, est codé en Q1.15, mais on sait que le facteur de mise à échelle pour une fenêtre de 1024 échantillons temporels l'a réduit à $\frac{1}{4}$ de la range possible du Q1.15, noté **Q1.15/4**;
- **r0***c le produit d'un nombre en Q2.15 avec un nombre Q1.15 est théoriquement un Q2.30 mais tient en pratique sur du **Q1.30**/2 puisque le *twiddle factor* est en Q1.15/4;
- $((\mathbf{r0^*c})+\mathbf{64})$ »7 le résultat en Q1.30/2 est ramené à du Q1.23/2 par une opération de shift avec arrondi (64 = 2^6 , ajouter un bit en $7^{\text{ème}}$ position en partant du LSB permet d'arrondir la valeur du $8^{\text{ème}}$ bit);
- ((i0*s)+64)»7 l'opération est équivalente à la précédente et est donc également codée en Q1.23/2;
- (((r0*c)+64)»7) + (((i0*s)+64)»7) l'addition de deux Q1.23/2 donne un Q1.23, codé sur 32 bits, il permet de conserver les 8 bits de *headroom* nécessaire à la FFT.

Les opérations de *post-processing* suivent elles aussi toujours le même schéma : les valeurs du spectre de fréquences sont calculées en additionnant deux produits d'un facteur de *twiddling* et d'une donnée de sortie de la FFT. Voici en exemple la conversion de la première opération de *post-twiddling* en *fixed point* :

$$spectrum[i] = -r0 * c - i0 * s;$$

devient

$$spectrum[i] = ((((-r0 + 128) >> 8) * c + 16384) >> 15) - ((((i0 + 128) >> 8) * s + 16384) >> 15);$$

où r0 et i0 sont les parties réelle et imaginaire des données de sortie de la FFT

r0 donnée de sortie de la FFT, est codé en Q9.23;

(-r0+128)»8 r0 est ramené en Q9.15 par un shift de 8 avec arrondi;

c twiddle factor, est codé en Q1.15, mais on sait que le facteur de mise à échelle pour une fenêtre de 1024 échantillons temporels l'a réduit à $\frac{1}{4}$ de la range possible du Q1.15, noté **Q1.15/4**;

((-r0+128)»8)*c la multiplication d'un Q9.15 par un Q1.15/4 donne un Q10.30/4 ou Q9.30/2;

(((-r0+128)»8)*c+16384)»15 le résultat en Q9.30/2 est ramené à du Q9.15/2 par un shift de 15 avec arrondi;

(((i0+128)»8)*s+16384)»15 le second terme effectue les mêmes opérations pour un résultat en Q9.15/2;

((((-r0+128))*8)*c+16384)*15) - ((((i0+128))*8)*s+16384)*15) la différence de deux Q9.15/2 est un Q10.15/2 ou Q9.15.

9.3 Validation

L'algorithme est validé par comparaison avec l'algorithme de référence. Le protocole de validation est détaillé dans la section 11.1 : les spectres sont générés par les différentes MDCT sur base du même signal temoprel pour que tous les spectres puissent être comparés entre eux. Afin de s'assurer de la cohérence des données produites par la MDCT, le signal d'entrée est un signal sinusoïdal : le spectre de fréquences ne doit donc mettre en évidence qu'une seule composante fréquentielle.

La figure 12 montre la comparaison entre le spectre de fréquences généré par la MDCT basée sur la FFT Ne10 en plain C et celui de référence en *integer* sur 32 bits (calculs en *double* mis à échalle Q15) pour un signal d'entrée à 200 Hz.




FIGURE 12 – Comparaison des spectres des fréquences produits par la MDCT Ne10 i32 plain C et par la MDCT de référence en *integer*

Le spectre de fréquences généré par la MDCT Ne10 i32 plain C (en pointillés) se superpose presque parfaitement au spectre de référence. La composante fréquentielle la plus haute se situe bien aux alentours de 200 Hz.

9.4 Performances

Les performances de la MDCT *fixed point* en *plain C* sont moins bonnes que celles de l'implémentation en *floating point* (voir section 11.2 pour plus d'explications sur la mesure des performances) :

- La MDCT Neon float 32 plain C a un temps d'exécution moyen de 9 μs;
- La MDCT *Neon integer 32 plain C* a un temps d'exécution moyen de 22 μs.

Le temps d'exécution notablement plus conséquent s'explique par le fait que l'architecture ARMv7 supporte de nombreuses opérations *floating point* sur 32 bits. Contrairement à des processeurs plus anciens, l'ARMv7 n'est donc pas plus efficace en arithmétique *fixed point*.

De plus, la section 9.2 a montré qu'une seule instruction en *floating point* était remplacée par plusieurs opérations *fixed point*. Une multiplication est, par exemple, remplacée par une multiplication, une rotation et une addition pour l'arrondi. Puisque les opérations sur des *integer* ne sont pas plus rapides que sur des *float*, il n'est donc pas étonnant que la MDCT *fixed point* soit plus lente que la MDCT *floating point*.

L'algorithme *fixed point* utilise également des opérations de *cast* d'*integer* en 32 bit vers du 64 bit. Ces opérations ont pour but d'éviter un dépassement qui se produit dans les opérations de *post-twiddling* et fausse les résultats obtenus. Sans ces opérations de *cast*, l'algorithme *fixed point* a un temps moyen d'exécution de 15 µs.

Ces explications sont cohérentes avec les mesures des performances des différentes FFT (section 8.4) : la FFT de Ne10 en int 32 plain C a un temps d'exécution moyen de 11 µs contre 6 µs pour la FFT Neon float 32 plain C et 5 µs pour la FFT FFTW3 float 32. À la perte de 5 µs dans l'exécution de la FFT s'ajoute donc 1 µs dû aux opérations de preet post-processing supplémentaire et 7 µs pour les opérations de cast.

10 Optimisations à l'architecture ARM

10.1 Spécificités de l'architecture ARMv7

Globalement reprend les tutos ARM

10.2 Utilisation des fonctions Neon SIMD (intrinsic)

Les opérations SIMD permettent de faire plusieurs opérations en une fois où l'algo normal n'en fait qu'une à la fois. L'algo SIMD permet de faire plusieurs modifications à la fois -> il faut ranger les données de manière à pouvoir l'appliquer facilement (fonction fenêtre -> tri des données?)

Plus les données sur lesquelles on travaille sont petites, plus on peut faire d'opérations en parallèle -> il faut voir si la perte de précision est ok. -> mettre une représentation graphique, c'est beaucoup plus simple à comprendre. D'où l'intérêt de passer à du 16 bits, plutôt que de rester en 32 bits et il faut absolument éviter le 64 bits (aucun intérêt).

Attention au flag pour la compilation + au header (accès aux intrinsics pas activé par défaut)




Figure 13

11 Analyse des résultats

11.1 Validation des données

Les sections précédentes ont montré que la les différentes itérations de la MDCT développées ont été validées à chaque étape. Cette validation consiste essentiellement en une vérification manuelle des données de sortie de la MDCT : avec un signal sinusoïdal connu en entrée, il est facile de vérifier que l'analyse fréquentielle ne contient bien qu'une seule composante fréquentielle, que la vérification se fasse en lisant les données brutes à la sortie de l'algorithme ou par une analyse graphique de celle-ci.

Ces tests auraient pu être améliorés en automatisant la vérification, e.g. en générant une fois les données de référence attendues pour permettre le développement d'un code de test qui compare automatiquement les données de références avec les données à vérifier. En effet, devoir relancer les tests et vérifier les données à chaque fois qu'une modification est faite dans le code peut s'avérer laborieux et mettre en place des tests automatiques aurait permis de gagner un temps précieux.

11.2 Gain en performance

La mesure des performances a pour but de valider le bloc MDCT avant de l'intégrer au codec AAC. Le cahier des charges du stage ne contenait pas d'objectif à atteindre en terme de performances, ni absolu (e.g. un temps d'exécution maximal à respecter dans des conditions données), ni relatif (e.g. gagner un certain pourcentage de performances par rapport à une MDCT de référence).

L'objectif en terme de temps d'exécution n'étant pas fini, il a été décidé de tenter de gagner le maximum de performances sur le temps de mon stage. Le critère de réussite est dès lors d'obtenir des performances au moins équivalentes pour la version finale de la MDCT que pour ses itérations précédentes.

Le temps d'exécution de la MDCT *fixed point* doit évidemment être inférieur au temps d'exécution de l'algorithme de référence puisque celui-ci ne contient aucune optimisation. Ce temps peut toutefois être équivalent au temps d'exécution de la MDCT *floating point* : à performances équivalentes, l'algorithme *fixed point* rendra tout de même l'encodeur AAC plus performant en économisant les transtypages *integer-floating point* à l'entrée et à la sortie du bloc MDCT. En effet, les données sont reçues par la MDCT en *integer* et devront être traitées en *integer* par le bloc de quantification à la sortie de la MDCT.

Le temps d'exécution des différentes itérations de la MDCT a été mesuré sur base du code de l'**annexe TODO** compilé par les commandes CMake présentées dans l'annexe l'**annexe TODO**. Le code permet de générer plusieurs exécutables en fonction de la variable de préprocesseur définie à la compilation, afin de pouvoir tester :

- La MDCT Ne10 float 32 plain C;
- La MDCT Ne10 integer 32 plain C;
- La MDCT Ne10 integer 32 neon;
- La MDCT de référence en float 32.

Le code de l'**annexe TODO**, compilé avec les commandes de l'**annexe TODO** génère un exécutable permettant de mesurer le temps moyen d'exécution de la MDCT *FFTW3 float 32*.

Les tests de performances sont lancés sur le Raspberry via une connexion SSH. Un script permet d'appeler tous les exécutables avec les paramètres voulus et les résultats affichés en console sont rediirigés vers un fichier texte. Les tests sont réalisés en isolation, i.e. aucun processus non nécessaire au fonctionnement du Raspberry n'est lancé durant la réalisation des tests pour ne pas interférer et risquer d'allonger le temps d'exécution. Les mesures de performances ont été prises avec des exécutables compilés en mode *release* avec l'option CMAKE_BUILD_TYPE=RELEASE.

Les résultats présentés dans la table 1 ont été mesurés sur 10 000 000 d'exécutions (10 000 pour l'algorithme de référence). Afin de ne pas introduire d'alétoire dans ces mesures, les MDCT ont toutes été testées avec le même signal temporel en entrée : un signal sinusoïdal à 440 Hz.

MDCT	Temps d'exécution moyen (ns)	Écart type (ns)
Ne10 i32 Neon	5796.35	0.02259×10^{-6}
Ne10 i32 C	22066.8	3.31025×10^{-6}
Ne10 f32	9020.1	0.02251×10^{-6}
FFTW3 f32	7446.84	1.29403×10^{-6}
Reference f32	29212.6×10 ³	0.77552×10^{-6}

Table 1 – Test de performance des algorithmes MDCT

Les résultats montrent que la MDCT optimisée avec les instructions SIMD Neon est bien plus rapide que les autres MDCT développées avec un temps d'exécution moyen de 5796.35 ns. L'objectif du stage est donc bien atteint.

L'algorithme MDCT de référence est le plus lent de tous avec un temps d'exécution moyen de 29 212.6 µs. Ce résultat est tout à fait normal puisque cet algoritme a été développé sans optimisation particulière.

La MDCT *fixed point* en *plain C* est la plus lente des MDCT optimisées avec un temps d'exécution moyen de 22 066.8 ns. La section 9.4 permet de comprendre en quoi ce résultat est cohérent puisque l'architecture ARMv7 supporte de nombreuses instructions en *float* sur 32 bits et que l'arithmétique *fixed point* nécessite souvent plusieurs opérations là où une seule est nécessaire en *floating point*.

Ces résultats montrent que l'implémentation des fonctions SIMD Neon était nécessaire afin d'obtenir des performances acceptables. Sans l'implémentation d'une MDCT optimisée avec ces instructions, l'utilisation d'une MDCT fixed point aurait été compromis par les résultats insatisfaisants de l'implémentation plain C.

Enfin, pour les implémentation *floating point plain C*, la MDCT *Ne10* est un peu plus lente que la MDCT *FFTW3* avec un temps d'exécution moyen de 9020.1 ns contre 7446.84 ns. Ce résultat est cohérent avec les performances des différentes FFT mesurées à la section 8.4 : la FFT de *FFTW3* en *float 32* est en effet environ 2 μs plus rapide que la FFT de *Ne10* en *float 32 plain C*.

11.3 Perte de précision

12 Améliorations possibles

- Fonction fenêtre intégrée aux opérations de pre twiddling
- Quantification intégrée au post twiddling
- tests automatisés
- code en C
- tests de performances plus poussés avec comparaison avec un algo existant

Conclusion

Sur base du cahier des charges de début de stage, il a été décidé que mon travail s

Références

- [1] EVS Website, "Page d'accueil d'EVS Broadcast Equipment." [https://evs.com], consulté le 21 avril 2022.
- [2] EVS Website, "Page de présentation des produits commercialisés par EVS Broadcast Equipment." [https://evs.com/products], consulté le 21 avril 2022.
- [3] K. Brandenburg, "Mp3 and aac explained," AES 17th International Conference on High Quality Audio Coding, 1999.
- [4] J. Herre and S. Dick, "Psychoacoustic models for perceptual audio coding—a tutorial review," *Applied Sciences*, vol. 9, p. 2854, 07 2019.
- [5] Wikipedia, "Codec." [https://en.wikipedia.org/wiki/Codec], consulté le 2 mai 2022.
- [6] Wikipedia, "Moving picture experts group." [https://en.wikipedia.org/wiki/Moving_Picture_Experts_Group], consulté le 30 mars 2022.
- [7] "Information technology Generic coding of moving pictures and associated audio information Part 7: Advanced Audio Coding (AAC)," standard, International Organization for Standardization, 2006. [https://www.iso.org/standard/43345.html].
- [8] "Information technology Coding of audio-visual objects Part 3: Audio," standard, International Organization for Standardization, 2019. [https://www.iso.org/standard/76383.html].
- [9] Wikipedia, "Psychoacoustics." [https://en.wikipedia.org/wiki/Psychoacoustics], consulté le 2 mars 2022.
- [10] Wikipedia, "Modified discrete cosine transform." [https://en.wikipedia.org/wiki/Modified_discrete_cosine_transform], consulté le 17 septembre 2021.
- [11] Project Ne10 Website, "Documentation du projet Ne10." [http://projectne10.github.io/Ne10/doc/], consulté le 9 mai 2022.
- [12] "The 3-Clause BSD License." [https://opensource.org/licenses/BSD-3-Clause], consulté le 9 mai 2022.
- [13] "Instruction Set Assembly Guide for Armv7 and earlier Arm architectures Version 2.0 Reference Guide," 2019. [https://developer.arm.com/documentation/100076/0200].
- [14] E. Oberstar, "Fixed-Point Representation & Fractional Math Revison 1.2," 08 2007.

Liste des annexes

A	CMake principal	Ι	
В	B Valeurs constantes des MDCT		
С	C.1 MDCT de référence en floating point	III III III	
D	D.1 Génération d'un signal sinusoïdal en floating point	IV IV IV	
	E.1 Header E.2 Constructeur E.3 Destructeur E.4 Fonction MDCT	V V V VI VI	
F	F.1 Code source	III III IX	
G	G.1 Header	X X X XI XI	
Н	Mesure des performances des FFT de Ne10XIH.1 Code sourceXH.2 CompilationX	III	
Ι	Mesure des performances des FFT de FFTW3XVI.1 Code sourceXI.2 CompilationX	VII	
J	Implémentation de la MDCT basée sur la FFT de Ne10 en fixed pointXIJ.1 HeaderXJ.2 ConstructeurXJ.3 DestructeurXI.4 Fonction MDCTX	IX XX	

K	Imp	lémentation de la MDCT basée sur la FFT de Ne10 en fixed point avec optimisations Neon	XXII
	K.1	Header	XXII
	K.2	Constructeur	XXII
	K.3	Destructeur	XXIII
	K.4	Fonction MDCT	XXIII
L	Con	nparaison des spectres de fréquences produits par les MDCT	XXVII
		Code source	
	L.2	Code source	XXVIII
M	Mes	ure des performances des MDCT <i>Ne10</i> et MDCT de référence	XXX
	M.1	Code source	XXX
	M.2	Compilation	XXXII
N			XXXIV
	N.1	Code source	XXXIV
	N.2	Compilation	XXXV

A CMake principal

Fichier CMake principal placé à la racine du projet. Il permet de compiler :

- le projet *audio_encoding* contenant les différentes MDCT et leurs tests : les commandes CMake de ce sous-projet sont présentées dans les annexes suivantes sous le code qu'elles permettent de compiler ;
- la librairie *Ne10* : les variables suivantes sont initialisées conformément aux recommendations de la documentation pour la compilation de la librairie :
 - NE10_LINUX_TARGET_ARCH est initialisée à armv7 (l'architecture du Raspberry Pi 4);
 - GNULINUX_PLATFORM est initialisée à ON;
 - BUILD_DEBUG est initialisée à ON si le projet est compilé en mode debug.

```
cmake_minimum_required(VERSION 3.13)

set(NE10_LINUX_TARGET_ARCH armv7)
set(GNULINUX_PLATFORM ON)
if (CMAKE_BUILD_TYPE STREQUAL "DEBUG")
    set(BUILD_DEBUG ON)
endif (CMAKE_BUILD_TYPE STREQUAL "DEBUG")

add_subdirectory(audio_encoding)
add_subdirectory(Ne10)
```

B Valeurs constantes des MDCT

Le fichier mdct_constants.h rassemble les valeurs constantes des MDCT pour une fenêtre d'entrée de 1024 échantillons.

```
// Sampling frequency: 48kHz
#define FS
                              48000
// Window length and derived constants
#define MDCT_WINDOW_LEN
#define MDCT_M
                              (\texttt{MDCT\_WINDOW\_LEN} > 1)
                                                        // spectrum size
                              (MDCT_WINDOW_LEN>>2)
                                                        // fft size
#define MDCT_M2
#define MDCT_M4
                              (MDCT_WINDOW_LEN>>3)
                              (3 * (MDCT_WINDOW_LEN > > 2))
#define MDCT_M32
#define MDCT_M52
                              (5 * (MDCT_WINDOW_LEN>>2))
```

C Algorithmes de référence

C.1 MDCT de référence en floating point

Algorithme de référence basé sur la formule mathématique de la MDCT. Le *template* permet de réaliser les calculs en *float* ou en *double*.

```
#include <math>
#include "mdct_constants.h"

template < typename FLOAT>
void ref_float_mdct(FLOAT * time_signal , FLOAT * spectrum)
{
    FLOAT scale = 2.0 / sqrt(MDCT_WINDOW_LEN);
    FLOAT factor1 = 2.0 * M_PI / static_cast < FLOAT>(MDCT_WINDOW_LEN);
    FLOAT factor2 = 0.5 + static_cast < FLOAT>(MDCT_M2);
    for (int k = 0; k < MDCT_M; ++k)
    {
        FLOAT result = 0.0;
        FLOAT factor3 = (k + 0.5) * factor1;
        for (int n = 0; n < MDCT_WINDOW_LEN; ++n)
        {
            result += time_signal[n] * cos((static_cast < FLOAT>(n) + factor2) * factor3);
        }
        spectrum[k] = scale * result;
    }
}
```

C.2 MDCT de référence en fixed point

Algorithme de référence basé sur la formule mathématique de la MDCT. Le spectre est calculé en *double* puis converti en *integer* sur 32 bits en représentation Q15.

D Génération d'un signal sinusoïdal

D.1 Génération d'un signal sinusoïdal en floating point

Code de génération d'un signal sinusoïdal en *float* ou en *double*. Le *template* permet de générer ces deux types de signaux avec le même code.

D.2 Génération d'un signal sinusoïdal en fixed point

La génération du signal sinusoïdal en *integer* fait appel à la génération du signal sinusoïdal en *double* avant de convertir le résultat en *integer* (représentation Q15).

E Implémentation de la MDCT basée sur la FFT de FFTW3

E.1 Header

Header de la classe mdct_fftw3_f32 : MDCT basée sur la FFT de la librairie *FFTW3* en *float* (32 bits). La classe contient les structures de données fft_in et fft_out, le tableau de facteurs de twiddle utilisé pour le pre- et le post-processing et la configuration de la FFT (fft_plan). L'implémentation des fonctions de ce header est présentée dans les annexes suivantes.

```
#include < fftw3.h>
#include "mdct_constants.h"
class fftw3_mdct_f32
    private:
    fftwf_plan fft_plan;
                                 // FFT configuration
    fftwf_complex *fft_in;
                                 // FFT input buffer
                                 // FFT output buffer
    fftwf_complex *fft_out;
    float twiddle[MDCT_M];
    public:
    fftw3_mdct_f32();
    \sim fftw3_mdct_f32();
    void \  \  mdct(\ float \  \  \star \ time\_signal \ , \  \  float \  \  \star spectrum \ );
    void imdct(float *spectrum, float *time_signal);
};
```

E.2 Constructeur

Initialisation de la MDCT dans le constructeur de la classe mdct_fftw3_f32:

- Le tableau de twiddle est initialisé en *float* sur 32 bits;
- La FFT de FFTW3 est initialisée en une dimension (pour l'audio) avec la taille de la FFT réduite à un quart de la taille de la fenêtre d'entrée par le pre-processing et avec l'option FFTW_MEASURE plus lente à l'initialisation mais qui permet d'optimiser le temps d'exécution de la FFT;
- Les tableaux contenant les données d'entrée (fft_in) et de sortie (fft_out) de la FFT sont alloués dynamiquement avec la fonction de FFTW3 et ils sont passés en paramètre à la configuration de la FFT.

```
#include <cmath>

fftw3_mdct_f32::fftw3_mdct_f32()
{
    float alpha = M_PI / (8.f * MDCT_M);
    float omega = M_PI / MDCT_M;
    float scale = sqrt(sqrt(2.f / MDCT_M));

    for (int i = 0; i < MDCT_M2; ++i)
    {
        float x = omega*i + alpha;
        twiddle[2*i] = scale * cos(x);
        twiddle[2*i+1] = scale * sin(x);
    }
}</pre>
```

```
fft_in = (fftwf_complex *) fftwf_malloc(sizeof(fftwf_complex) * MDCT_M2);
fft_out = (fftwf_complex *) fftwf_malloc(sizeof(fftwf_complex) * MDCT_M2);
fft_plan = fftwf_plan_dft_1d(MDCT_M2, fft_in, fft_out, FFTW_FORWARD, FFTW_MEASURE);
}
```

E.3 Destructeur

Destructeur de la classe mdct_fftw3_f32 qui permet de libérer la mémoire allouée aux tableaux d'entrée et de sortie de la FFT et à sa configuration avec les fonctions appropriées fournies par la librairie FFTW3.

```
fftw3_mdct_f32::~fftw3_mdct_f32()
{
    fftwf_destroy_plan(fft_plan);
    fftwf_free(fft_in);
    fftwf_free(fft_out);
}
```

E.4 Fonction MDCT

Implémentation de l'algorithme de MDCT basé sur la FFT de la librairie FFTW3 :

- Initialisation du tableau d'entrée de la FFT : les opérations de *pre-twiddling* permettent de réduire la fenêtre d'entrée de la FFT ;
- Appel de la fonction FFT de *FFTW3*;
- Calcul du spectre de fréquences : les opérations de *post-twiddling* permettent de calculer le spectre à partir des données de sortie de la FFT et des facteurs de *twiddle*.

```
void fftw3_mdct_f32::mdct(float *time_signal, float *spectrum)
    float *cos_tw = twiddle;
    float *sin_tw = cos_tw + 1;
    /* odd/even folding and pre-twiddle */
    float *xr = (float *) fft_in;
    float *xi = xr + 1;
    for (int i = 0; i < MDCT_M2; i += 2)
        float r0 = time_signal[MDCT_M32-1-i] + time_signal[MDCT_M32+i];
        float i0 = time_signal[MDCT_M2+i] - time_signal[MDCT_M2-1-i];
        float c = cos_tw[i];
        float s = sin_tw[i];
        xr[i] = r0 * c + i0 * s;
        xi[i] = i0*c - r0*s;
    for(int i = MDCT_M2; i < MDCT_M; i += 2)
        float r0 = time_signal[MDCT_M32-1-i] - time_signal[-MDCT_M2+i];
        float i0 = time_signal[MDCT_M2+i] + time_signal[MDCT_M52-1-i];
```

```
float c = cos_tw[i];
  float s = sin_tw[i];

    xr[i] = r0*c + i0*s;
    xi[i] = i0*c - r0*s;
}

/* complex FFT of size MDCT_M2 */
fftwf_execute(fft_plan);

/* post-twiddle */
    xr = (float *) fft_out;
    xi = xr + 1;

for (int i = 0; i < MDCT_M; i += 2) {
    float r0 = xr[i];
    float i0 = xi[i];
    float s = sin_tw[i];
    float s = sin_tw[i];
    spectrum[i] = -r0*c - i0*s;
    spectrum[MDCT_M-1-i] = -r0*s + i0*c;
}
</pre>
```

F Validation de la MDCT FFTW3 en float 32

F.1 Code source

Test de la MDCT basée sur la FFT de FFTW3 en float 32 avec un signal d'entrée sinusoïdal à 200 Hz :

- Génération et affichage d'un signal sinusoïdal à 200 Hz;
- Calcul et affichage du spectre de fréquences de ce signal;
- Opération inverse de la MDCT et affichage du signal temporel calculé à partir du spectre.

Les différentes données sont écrites dans un fichier CSV afin de pouvoir les exploiter sous forme graphique.

```
#include <iomanip >
#include <iostream >
#include <fstream >
#include < cstring >
#include "mdct_constants.h"
#include "fftw3_mdct_f32.h"
#include "sin_wave.h"
    * @brief MDCT algorithm calling the FFT of the fftw3 library
    * Code based on https://www.dsprelated.com/showcode/196.php
    * Change the MDCT_WINDOW_LEN to test the MDCT with other spectrum sizes
int main (void)
    // input time signal (200 Hz)
    float time_in[MDCT_WINDOW_LEN];
    sin_float(time_in, MDCT_WINDOW_LEN, 0.9, 200.0, 0.0, FS);
    // output time signal (generated by the IMDCT)
    float time_out[MDCT_WINDOW_LEN];
    memset(time_out, 0, MDCT_WINDOW_LEN* size of (float));
    // frequency spectrum (generated by the MDCT)
    float spectrum[MDCT_M];
    memset(spectrum, 0, MDCT_M* sizeof(float));
    // perform the MDCT and IMDCT
    fftw3_mdct_f32 fftw3_mdct;
    fftw3_mdct.mdct(time_in, spectrum);
    fftw3_mdct.imdct(spectrum, time_out);
    // print the results in CSV file
    std::ofstream csv_file;
    csv_file.open("fftw3_mdct_f32.csv");
    csv_file << "time_(ms), signal_in, signal_out, frequency_(Hz), spectrum" << std::endl;
    for (int i = 0; i < MDCT_M; ++i)
        csv_file << i*1000.0/FS << "," << time_in[i] << "," << time_out[i] << ","
            <<~(i+1.0)*FS/MDCT\_WINDOW\_LEN~<<~","~<<~std::abs(spectrum[i])~<<~","~<<~std::endl;
```

```
for (int i = MDCT_M; i < MDCT_WINDOW_LEN; ++i)
{
     csv_file << i*1000.0/(FS) << "," << time_in[i] << "," << time_out[i] << "," << std::endl;
}

csv_file.close();
return 0;
}</pre>
```

F.2 Compilation

Commandes CMake permettant de compiler le code d'exemple.

```
# MDCT using the fftw3 library f32
add_executable(fftw3_mdct_f32 test/validation/fftw3_example.cpp
    src/fftw3_mdct_f32.cpp src/sin_wave.cpp)
target_link_libraries(fftw3_mdct_f32 fftw3f)
```

G Implémentation de la MDCT basée sur la FFT de Ne10 en floating point

G.1 Header

Header de la classe mdct_ne10_f32_c : MDCT basée sur la FFT de la librairie Ne10 en float (32 bits). La classe contient les structures de données fft_in et fft_out, le tableau de facteurs de twiddle utilisé pour le pre- et le post-processing et la configuration de la FFT (cfg). L'implémentation des fonctions de ce header est présentée dans les annexes suivantes.

G.2 Constructeur

Initialisation de la MDCT dans le constructeur de la classe mdct_ne10_f32_c :

- Le tableau de twiddle est initialisé en *float* sur 32 bits;
- La configuration de la FFT de *Ne10* est initialisée en *complex to complex* en *float 32* avec en paramètre la taille de la fenêtre de la FFT réduite à un quart de la taille de la fenêtre d'entrée.

```
ne10_mdct_f32_c::ne10_mdct_f32_c()
{
    float alpha = M_PI / (8.0 * static_cast < float > (MDCT_M));
    float omega = M_PI / static_cast < float > (MDCT_M);
    float scale = sqrt(sqrt(2.0 / static_cast < float > (MDCT_M)));
    for (int i = 0; i < MDCT_M2; ++i)
    {
        float x = omega * i + alpha;
        twiddle[2*i] = static_cast < float > (scale * cos(x));
        twiddle[2*i+1] = static_cast < float > (scale * sin(x));
    }
    cfg = ne10_fft_alloc_c2c_float32_c(MDCT_M2);
}
```

G.3 Destructeur

Destructeur de la classe mdct_ne10_f32_c qui permet de libérer la mémoire allouée à la configuration de la FFT avec la fonction appropriée de la librairie *Ne10*.

G.4 Fonction MDCT

Implémentation de l'algorithme de MDCT basé sur la FFT de la librairie Ne10 en float 32 et en plain C:

- Initialisation du tableau d'entrée de la FFT : les opérations de *pre-twiddling* permettent de réduire la fenêtre d'entrée de la FFT ;
- Appel de la fonction FFT de *Ne10*;
- Calcul du spectre de fréquences : les opérations de *post-twiddling* permettent de calculer le spectre à partir des données de sortie de la FFT et des facteurs de *twiddle*.

```
void ne10_mdct_f32_c::mdct(float *time_signal, float *spectrum)
    // pre-twiddling
    float *cos_tw = twiddle;
    float *sin_tw = cos_tw + 1;
    for (int i = 0; i < MDCT M2; i += 2)
        float r0 = time_signal[MDCT_M32-1-i] + time_signal[MDCT_M32+i];
        float i0 = time_signal[MDCT_M2+i] - time_signal[MDCT_M2-1-i];
        float c = cos_tw[i];
        float s = sin_tw[i];
        fft_in[i/2].r = r0*c + i0*s;
        fft_in[i/2].i = i0*c - r0*s;
    for (int i = MDCT_M2; i < (MDCT_M); i += 2)</pre>
        float r0 = time_signal[MDCT_M32-1-i] - time_signal[-MDCT_M2+i];
        float i0 = time_signal[MDCT_M2+i] + time_signal[MDCT_M52-1-i];
        float c = cos_tw[i];
        float s = sin_tw[i];
        fft_in[i/2].r = r0*c + i0*s;
        fft_in[i/2].i = i0 * c - r0 * s;
    }
    // FFT
    ne10_fft_c2c_1d_float32_c(fft_out, fft_in, cfg, 0);
```

```
for (int i = 0; i < (MDCT_M); i += 2)
{
    float r0 = fft_out[i/2].r;
    float i0 = fft_out[i/2].i;

    float c = cos_tw[i];
    float s = sin_tw[i];

    spectrum[i] = -r0*c - i0*s;
    spectrum[(MDCT_M)-1-i] = -r0*s + i0*c;
}
</pre>
```

H Mesure des performances des FFT de Ne10

H.1 Code source

Code permettant de tester la vitesse d'exécution moyenne de différentes FFT proposées par la librairie Ne10. La moyenne est calculée sur 10 000 000 d'exécutions. Les données d'entrée de la FFT sont générées aléatoirement et sont différentes pour chaque exécution. Les variables de préprocesseur définies à la compilation permettent à partir du même code de mesurer le temps d'exécution moyen avec écart type :

- de la FFT *complex to complex* en *float 32* en *plain C* ou avec les optimisations Neon;
- de la FFT *complex to complex* en *integer 32* en *plain C* ou avec les optimisations Neon;
- de la FFT complex to complex en integer 16 en plain C ou avec les optimisations Neon.

```
#include <iomanip >
#include <iostream >
#include < limits >
#include < cmath >
#include < cstring >
#include "mdct_constants.h"
#include "Timers.h"
#include "NE10.h"
                     // 32 bits floating point arithmetic
#ifdef F32
#define INPUT_RANGE
#define INPUT DATA
                                    ne10\_fft\_cpx\_float32\_t
#define OUTPUT_DATA
                                    ne10_fft_cpx_float32_t
#define FFT_CONFIG
                                    ne10_fft_cfg_float32_t
#define DESTROY_CONFIG
                                    ne10_fft_destroy_c2c_float32
#ifdef NEON
#define ALLOC_CONFIG
                                    ne10\_fft\_alloc\_c2c\_float32\_neon
#define PERFORM_FFT
                                    ne10_fft_c2c_1d_float32_neon
#else
#define ALLOC_CONFIG
                                    ne10_fft_alloc_c2c_float32_c
#define PERFORM FFT
                                    n\,e\,1\,0\,\_fft\,\_c\,2\,c\,\_1\,d\,\_f\,l\,o\,a\,t\,3\,2\,\_c
#endif
#elif I32
                      // 32 bits fixed point arithmetic
#define INPUT RANGE
                                    std::numeric limits < int16 t >::max() * 2
#define INPUT_DATA
                                    ne10_fft_cpx_int32_t
#define OUTPUT_DATA
                                    n\,e\,1\,0\,\_fft\,\_c\,p\,x\,\_i\,n\,t\,3\,2\,\_t
#define FFT_CONFIG
                                    ne10_fft_cfg_int32_t
#define DESTROY_CONFIG
                                    ne10_fft_destroy_c2c_int32
#ifdef NEON
                                    ne10\_fft\_alloc\_c2c\_int32\_neon
#define ALLOC_CONFIG
#define PERFORM FFT
                                    ne10_fft_c2c_1d_int32_neon
#else
#define ALLOC_CONFIG
                                    ne10_fft_alloc_c2c_int32_c
#define PERFORM_FFT
                                    ne10_fft_c2c_1d_int32_c
#endif
```

```
// 16 bits fixed point arithmetic
#else
#define INPUT_RANGE
                                  std:: numeric_limits < int16_t > :: max() * 2
#define INPUT_DATA
                                  ne10_fft_cpx_int16_t
#define OUTPUT DATA
                                  ne10_fft_cpx_int16_t
#define FFT_CONFIG
                                  ne10_fft_cfg_int16_t
#define ALLOC_CONFIG
                                  ne10\_fft\_alloc\_c2c\_int16
#define DESTROY_CONFIG
                                  ne10_fft_destroy_c2c_int16
#ifdef NEON
#define PERFORM_FFT
                                 ne10_fft_c2c_1d_int16_neon
#else
#define PERFORM_FFT
                                 ne10_fft_c2c_1d_int16_c
#endif
#endif
#define RUNS
                          10000000
#define FFT_SCALE_FLAG 0
int main()
    // print which FFT will be tested
#ifdef F32
#ifdef NEON
    std::cout << "FFT_Ne10_f32_Neon" << std::endl;
    std::cout << "FFT_Ne10_f32_plain_C" << std::endl;
#endif
#elif I32
#ifdef NEON
    std::cout << "FFT_Ne10_i32_Neon" << std::endl;
    std::cout << \ "FFT \_Ne10 \_i32 \_plain \_C" << \ std::endl;\\
#endif
#else
#ifdef NEON
    std::cout << "FFT_Ne10_i16_Neon" << std::endl;
    std::cout << "FFT_Ne10_i16_plain_C" << std::endl;
#endif
#endif
    // seed the random
    srand(static_cast < unsigned > (time(0)));
    // initialize the configuration
    FFT_CONFIG cfg = ALLOC_CONFIG(MDCT_M2);
    // start the loop executing the FFTs
    int64_t *runtimes = static_cast <int64_t *>(malloc(RUNS * sizeof(int64_t)));
    for (int i = 0; i < RUNS; ++i)
        // initialize an empty spectrum
        OUTPUT\_DATA \ spectrum [MDCT\_M2] \_\_attribute\_\_ ((\ aligned \ (1 \ 6)));
        memset(\&\,spectrum\,\,,\,\,\ 0\,\,,\,\,\,(MDCT\_M2)*\,\,\textbf{sizeof}\,\,(OUTPUT\_DATA\,)\,)\,;
```

```
// generate random input data
        INPUT_DATA time_signal[MDCT_M2] __attribute__ ((aligned(16)));
        for (int i = 0; i < MDCT_M2; ++i)
            time_signal[i].r = INPUT_RANGE * rand() / RAND_MAX - INPUT_RANGE / 2;
            time_signal[i].i = INPUT_RANGE * rand() / RAND_MAX - INPUT_RANGE / 2;
        // perfom the FFT and measure the run time
        EvsHwLGPL::CTimers timer;
        timer. Start();
#ifdef F32
        PERFORM_FFT(time_signal, spectrum, cfg, 0);
#else
        PERFORM_FFT(time_signal, spectrum, cfg, 0, FFT_SCALE_FLAG);
#endif
        timer.Stop();
        runtimes[i] = timer.GetTimeElapsed();
    // clean
   DESTROY_CONFIG( cfg );
    // compute the average
    double avg = 0.0;
    for (int i = 0; i < RUNS; ++i) avg += static_cast < double > (runtimes[i]);
    avg = avg / static_cast < double > (RUNS);
    std::cout << \ "average \_run \_time: \_ \_ \_ " << \ avg << \ " \_ ns" << \ std::endl;
    // compute the standard deviation
    double dev = 0.0;
    for (int i = 0; i < RUNS; ++i) dev += static_cast < double > (runtimes [i]) - avg;
    dev = dev * dev / static_cast < double > (RUNS);
    dev = sqrt(dev);
    std::cout << "standard_deviation:_" << dev << "_ns" << std::endl;
    return 0;
```

H.2 Compilation

Commandes CMake utilisées pour générer les exécutables permettant de mesurer le temps d'exécution de différentes FFT proposées par la librairie *Ne10*. En fonction des variables de préprocesseur définies, les exéctables suivants sont générés :

- run_fft_f32_c est généré si la variable F32 est définie pour mesurer le temps d'exécution de la FFT float 32 plain C;
- run_fft_i32_c est généré si la variable I32 est définie pour mesurer le temps d'exécution de la FFT *integer* 32 plain C;
- run_fft_i16_c est généré par défaut pour mesurer le temps d'exécution de la FFT integer 16 plain C;
- run_fft_f32_neon est généré si les variables F32 et NEON sont définies pour mesurer le temps d'exécution de la FFT *float 32* avec optimisations *Neon*;
- run_fft_i32_neon est généré si les variables I32 et NEON sont définies pour mesurer le temps d'exécution de la FFT *integer 32* avec optimisations *Neon*;

• run_fft_i16_neon est généré si la variable NEON est définie pour mesurer le temps d'exécution de la FFT *integer 16* avec optimisations *Neon*.

```
# Ne10 FFT performance (float32 plain C)
add_executable(run_ne10_fft_f32_c test/performance/run_ne10_fft.cpp src/Timers.cpp)
target_compile_definitions(run_ne10_fft_f32_c PUBLIC -DF32)
target_link_libraries(run_ne10_fft_f32_c NE10)
# Ne10 FFT performance (int32 plain C)
add_executable(run_ne10_fft_i32_c test/performance/run_ne10_fft.cpp src/Timers.cpp)
target_compile_definitions(run_ne10_fft_i32_c PUBLIC -DI32)
target_link_libraries(run_ne10_fft_i32_c NE10)
# Ne10 FFT performance (int16 plain C)
add_executable(run_ne10_fft_i16_c test/performance/run_ne10_fft.cpp src/Timers.cpp)
target_compile_definitions(run_ne10_fft_i16_c PUBLIC -DI16)
target_link_libraries(run_ne10_fft_i16_c NE10)
# Ne10 FFT performance (float32 with neon optimizations)
add_executable(run_ne10_fft_f32_neon test/performance/run_ne10_fft.cpp src/Timers.cpp)
target_compile_definitions(run_ne10_fft_f32_neon PUBLIC -DF32 -DNEON)
target_link_libraries(run_ne10_fft_f32_neon NE10)
# Ne10 FFT performance (int32 with neon optimizations)
add_executable(run_ne10_fft_i32_neon test/performance/run_ne10_fft.cpp src/Timers.cpp)
target_compile_definitions(run_ne10_fft_i32_neon PUBLIC -DI32 -DNEON)
target_link_libraries(run_ne10_fft_i32_neon NE10)
# Ne10 FFT performance (int16 with neon optimizations)
add_executable(run_ne10_fft_i16_neon_test/performance/run_ne10_fft.cpp_src/Timers.cpp)
target_compile_definitions(run_ne10_fft_i16_neon PUBLIC -DI16 -DNEON)
target_link_libraries(run_ne10_fft_i16_neon NE10)
```

I Mesure des performances des FFT de FFTW3

I.1 Code source

Code permettant de tester la vitesse d'exécution moyenne de la FFT en *float 32* de la librairie *FFTW3*. La moyenne est calculée sur 10 000 000 d'exécutions. Les données d'entrée de la FFT sont générées aléatoirement et sont différentes pour chaque exécution.

```
#include <iomanip >
#include <iostream >
#include < cmath >
#include < fftw3.h>
#include "mdct_constants.h"
#include "Timers.h"
#define RUNS 10000000
int main()
    // print which FFT will be tested
    std::cout << "FFT_FFTW3_f32_plain_C" << std::endl;
    // seed the random
    srand(static_cast < unsigned > (time(0)));
    // start the loop executing the FFTs
    int64_t *runtimes = static_cast < int64_t *> (malloc(RUNS * sizeof(int64_t)));
    for (int i = 0; i < RUNS; ++i)
        // initialize an empty spectrum
        fftwf_complex *fft_out = (fftwf_complex *) fftwf_malloc(sizeof(fftwf_complex) * MDCT_M2);
        // generate random input data
        fftwf_complex *fft_in = (fftwf_complex *)fftwf_malloc(sizeof(fftwf_complex) * MDCT_M2);
        float *x = (float *) fft_in;
        for (int i = 0; i < MDCT_M2; ++ i)
            x[i] = 1.8 f * rand() / RAND_MAX - 1.8 f / 2.0 f;
        // initialize the configuration
        fftwf_plan fft_plan = fftwf_plan_dft_1d(MDCT_M2, fft_in, fft_out,
            FFTW_FORWARD, FFTW_MEASURE);
        // perfom the FFT and measure the run time
        EvsHwLGPL::CTimers timer;
        timer.Start();
        fftwf_execute(fft_plan);
        timer.Stop();
        runtimes[i] = timer.GetTimeElapsed();
        fftwf_destroy_plan(fft_plan);
        fftwf_free(fft_in);
        fftwf_free(fft_out);
```

```
// compute the average
double avg = 0.0;
for (int i = 0; i < RUNS; ++i) avg += static_cast < double > (runtimes[i]);
avg = avg / static_cast < double > (RUNS);
std::cout << "average_run_time:____" << avg << "__ns" << std::endl;

// compute the standard deviation
double dev = 0.0;
for (int i = 0; i < RUNS; ++i) dev += static_cast < double > (runtimes[i]) - avg;
dev = dev * dev / static_cast < double > (RUNS);
dev = sqrt(dev);
std::cout << "standard_deviation:_" << dev << "__ns" << std::endl;
return 0;
}</pre>
```

I.2 Compilation

Commandes CMake utilisées pour générer l'exécutable permettant de mesurer le temps d'exécution de la FFT *float* 32 de la librairie *FFTW3*.

```
# FFTW3 FFT performance (float32)
add_executable(run_fftw3_fft_f32 test/performance/run_fftw3_fft_f32.cpp src/Timers.cpp)
target_link_libraries(run_fftw3_fft_f32 fftw3f)
```

J Implémentation de la MDCT basée sur la FFT de Ne10 en fixed point

J.1 Header

Header de la classe mdct_ne10_i32_c: MDCT basée sur la FFT de la librairie Ne10 en integer (32 bits). La classe contient les structures de données fft_in en représentation Q1.15 et fft_out en Q9.15, le tableau de facteurs de twiddle utilisé pour le pre- et le post-processing et la configuration de la FFT (cfg). L'implémentation des fonctions de ce header est présentée dans les annexes suivantes.

```
#pragma once
#include "mdct_constants.h"
#include "NE10.h"
class ne10_mdct_i32_c
    private:
    ne10 fft cfg int32 t cfg;
                                                                        // Ne10 configuration
    ne10_fft_cpx_int32_t fft_in[MDCT_M2]__attribute__((aligned(16))); // Ne10 FFT input buffer
                                                                            Q1.15
    ne10_fft_cpx_int32_t fft_out[MDCT_M2]__attribute__((aligned(16))); // Ne10 FFT output buffer
                                                                        // Q9.15
                                                                        // MDCT twiddle factors
    int16_t twiddle[MDCT_M] __attribute__ ((aligned(16)));
    public:
    ne10_mdct_i32_c();
    ~ne10_mdct_i32_c();
    void mdct(int16_t *time_signal, int32_t *spectrum);
};
```

I.2 Constructeur

Initialisation de la MDCT dans le constructeur de la classe mdct_ne10_i32_c :

- Le tableau de twiddle est initialisé en double puis converti en integer (représentation Q15);
- La configuration de la FFT de *Ne10* est initialisée en *complex to complex* en *integer 32* avec en paramètre la taille de la fenêtre de la FFT réduite à un quart de la taille de la fenêtre d'entrée.

```
ne10_mdct_i32_c::ne10_mdct_i32_c()
{
    // intialize the twiddling factors
    double alpha = M_PI / (8.0*MDCT_M);
    double omega = M_PI / MDCT_M;
    double scale = sqrt(sqrt(2.0 / static_cast < double > MDCT_M));
    for (int i = 0; i < MDCT_M2; ++i)
    {
        double x = omega * i + alpha;
        twiddle[2*i] = static_cast < int16_t > (cos(x)*scale*pow(2.0, 15.0));
        twiddle[2*i+1] = static_cast < int16_t > (sin(x)*scale*pow(2.0, 15.0));
}

// initialize the Ne10 FFT configuration
    cfg = ne10_fft_alloc_c2c_int32_c(MDCT_M2);
}
```

J.3 Destructeur

Destructeur de la classe mdct_ne10_i32_c qui permet de libérer la mémoire allouée à la configuration de la FFT avec la fonction appropriée de la librairie *Ne10*.

J.4 Fonction MDCT

Implémentation de l'algorithme de MDCT basé sur la FFT de la librairie Ne10 en integer 32 et en plain C:

- Initialisation du tableau d'entrée de la FFT : les opérations de *pre-twiddling* permettant de réduire la fenêtre d'entrée de la FFT sont faites en algorithmique *fixed point*;
- Appel de la fonction FFT de Ne10;
- Calcul du spectre de fréquences : les opérations de *post-twiddling* permettant de calculer le spectre à partir des données de sortie de la FFT et des facteurs de *twiddle* sont faites en algorithmique *fixed point*.

```
void ne10_mdct_i32_c :: mdct(int16_t *time_signal, int32_t *spectrum)
    // pre-twiddling
    // fft_in = (Q1.15 + Q1.15) * Q1.15/4 + (Q1.15 + Q1.15) * Q1.15/4
                1/4 Q1.30 + 1/4 Q1.30 + 1/4 Q1.30 + 1/4 Q1.30 -> Q1.30
    //
                >>7 -> Q1.23 + 8 bits reserved for the FFT
    int16_t *cos_tw = twiddle;
    int16_t * sin_tw = cos_tw + 1;
    for (int i = 0; i < MDCT_M2; i += 2)
        int32_t r0 = static_cast < int32_t > (time_signal[MDCT_M32-1-i]) + time_signal[MDCT_M32+i];
        int32_t i0 = static_cast <int32_t >(time_signal[MDCT_M2+i]) - time_signal[MDCT_M2-1-i];
        int16_t c = cos_tw[i];
        int16_t s = sin_tw[i];
        fft_in[i/2].r = (((r0*c)+64)>>7) + (((i0*s)+64)>>7);
        fft_in[i/2].i = (((i0*c)+64)>>7) - (((r0*s)+64)>>7);
    for (int i = MDCT_M2; i < MDCT_M; i += 2)
        int32_t r0 = static_cast <int32_t >(time_signal[MDCT_M32-1-i]) - time_signal[-MDCT_M2+i];
        int32\_t i0 = static\_cast < int32\_t > (time\_signal[MDCT\_M2+i]) + time\_signal[MDCT\_M52-1-i];
        int16_t c = cos_tw[i];
        int16_t s = sin_tw[i];
        fft_in[i/2].r = (((r0*c)+64)>>7) + (((i0*s)+64)>>7);
        fft_in[i/2].i = (((i0*c)+64)>>7) - (((r0*s)+64)>>7);
    // perform the FFT
    ne10_fft_c2c_1d_int32_c(fft_out, fft_in, cfg, 0, 0);
```

```
// post-twiddling
// spectrum = Q9.23 > 8 * Q1.15/4 + Q9.23 > 8 * Q1.15/4
// = Q9.15 * Q1.15/4 + Q9.15 * Q1.15/4
             = Q9.15 * Q1.15/4 + Q9.15 * Q1.15/4
               = Q10.30/4 + Q10.30/4
//
//
              = Q11.30/4
// = Q9.30 >> 15 = Q9.15
for (int i = 0; i < MDCT_M; i += 2)
     int32_t r0 = fft_out[i/2].r;
     int32_t i0 = fft_out[i/2].i;
     int16_t c = cos_tw[i];
     int16_t = sin_tw[i];
     spectrum[i] = (((-(static_cast < int64_t > (r0) + 128) > >8) * c + 16384) > >15)
         - ((((static_cast < int64_t > (i0) + 128) > >8)*s + 16384) > >15);
     spectrum [MDCT_M-1-i] = ((((-static_cast < int64_t > (r0) + 128) > >8) * s + 16384) > >15) \\ + ((((static_cast < int64_t > (i0) + 128) > >8) * c + 16384) > >15);
}
```

K Implémentation de la MDCT basée sur la FFT de Ne10 en fixed point avec optimisations Neon

K.1 Header

Header de la classe mdct_ne10_i32_neon : MDCT basée sur la FFT de la librairie Ne10 en integer (32 bits) optimisée par l'utilisation des opérations SIMD Neon. La classe contient les structures de données fft_in en représentation Q1.15 et fft_out en Q9.15, les tableaux de facteurs de twiddle utilisés pour le pre- et le post-processing et la configuration de la FFT (cfg). Contrairement aux autres implémentations, les facteurs de twiddle ne sont pas rassemblés dans un seul tableau. Les tableaux de facteurs de pre-twiddling et de post-twiddling sont séparés car ils sont utilisés en 16 bits pour le pre-twiddling et en 32 bits pour le post-twiddling. Chacun de ces tableaux est séparé en deux afin que chaque moitié puisse être initialisée dans un ordre qui facilite l'utilisation des opérations SIMD. L'implémentation des fonctions de ce header est présentée dans les annexes suivantes.

```
#pragma once
#include <arm_neon.h>
#include "mdct_constants.h"
#include "NE10.h"
class ne10_mdct_i32_neon
private:
    n\,e\,1\,0\,\_fft\,\_c\,fg\,\_i\,n\,t\,3\,2\,\_t\ c\,fg\;;
                                                                              // Ne10 configuration
    ne10\_fft\_cpx\_int32\_t \quad fft\_in \, [MDCT\_M2] \, \_\_attribute\_\_\, ((\, aligned \, (16)));
                                                                              // Ne10 FFT input buffer
    ne10_fft_cpx_int32_t fft_out[MDCT_M2]__attribute__((aligned(16))); // Ne10 FFT output buffer
    int16_t pretwiddle_start[MDCT_M2]__attribute__((aligned(16)));
                                                                              // pre-twiddle factors
    int16_t pretwiddle_end[MDCT_M2] __attribute__ ((aligned(16)));
                                                                                 second half is stored
                                                                                  in reversed order
    int32 t posttwiddle start[MDCT M2] attribute ((aligned(16)));
                                                                              // post-twiddle factors
    int32_t posttwiddle_end[MDCT_M2] __attribute__ ((aligned(16)));
                                                                              // second half is stored
                                                                              // in reversed order
public:
    ne10_mdct_i32_neon();
    ~ne10_mdct_i32_neon();
    void mdct(int16_t *time_signal, int32_t *spectrum);
```

K.2 Constructeur

Initialisation de la MDCT dans le constructeur de la classe mdct_ne10_i32_neon :

- Le tableau de twiddle est initialisé en *double* puis converti en *integer* (représentation Q15 en 16 bits pour le *pre-twiddling* et en 32 bits pour le *post-twiddling*): la première moitié des tableaux est rangée à l'endroit dans les tableaux pretwiddle_start et posttwiddle_start tandis que la seconde est rangée à l'envers dans les tableaux pretwiddle_end et posttwiddle_end;
- La configuration de la FFT de *Ne10* est initialisée en *complex to complex* en *integer 32* avec en paramètre la taille de la fenêtre de la FFT réduite à un quart de la taille de la fenêtre d'entrée avec la fonction adaptée pour l'exécution d'une FFT optimisée avec les instructions SIMD Neon.

```
ne10_mdct_i32_neon:: ne10_mdct_i32_neon()
    double alpha = M_PI / (8.0*MDCT_M);
    double omega = M_PI / MDCT_M;
    double scale = sqrt(sqrt(2.0 / static_cast < double > MDCT_M));
    for (int i = 0; i < MDCT_M4; ++i)
        double start = omega * (i) + alpha;
        double end = omega * (i+MDCT_M4) + alpha;
        double cos_start = cos(start);
        double sin_start = sin(start);
        double cos_end = cos(end);
        double sin_end = sin(end);
        pretwiddle_start[2*i] = static_cast < int16_t > (cos_start * scale * pow(2.0, 15.0));
        pretwiddle_start[2*i+1] = static_cast < int16_t > (sin_start * scale * pow(2.0, 15.0));
        pretwiddle_end[MDCT_M2-2*i-2] = static_cast < int16_t > (cos_end*scale*pow(2.0, 15.0));
        pretwiddle\_end[MDCT\_M2-2*i-1] = static\_cast < int16_t > (sin\_end*scale*pow(2.0, 15.0));
        posttwiddle_start[2*i] = static_cast <int32_t >(cos_start * scale *pow(2.0, 31.0));
        posttwiddle_start[2*i+1] = static_cast < int32_t > (sin_start * scale * pow(2.0, 31.0));
        posttwiddle_end[MDCT_M2-2*i-2] = static_cast < int32_t > (cos_end * scale * pow(2.0, 31.0));
        posttwiddle_end[MDCT_M2-2*i-1] = static_cast < int32_t > (sin_end*scale*pow(2.0, 31.0));
    cfg = ne10_fft_alloc_c2c_int32_neon(MDCT_M2);
```

K.3 Destructeur

Destructeur de la classe mdct_ne10_i32_c qui permet de libérer la mémoire allouée à la configuration de la FFT avec la fonction appropriée de la librairie *Ne10*.

```
ne10_mdct_i32_neon ::~ ne10_mdct_i32_neon ()
{
    ne10_fft_destroy_c2c_int32 (cfg );
}
```

K.4 Fonction MDCT

Implémentation de l'algorithme de MDCT basé sur la FFT de la librairie Ne10 en integer 32 avec utilisation des instructions SIMD Neon :

- Initialisation du tableau d'entrée de la FFT : les opérations de *pre-twiddling* permettant de réduire la fenêtre d'entrée de la FFT sont faites en algorithmique *fixed point*. L'utilisation des fonctions SIMD permet d'effectuer quatre opérations en parallèle afin de réduire le temps d'exécution. Les facteurs de *pre-twiddling* codés sur 16 bits transforment le signal d'entrée codé sur 16 bits en un tableau d'entrée de la FFT codé sur 32 bits;
- Appel de la fonction FFT de *Ne10* optimisée par l'utilisation des instructions SIMD Neon;
- Calcul du spectre de fréquences : les opérations de *post-twiddling* permettant de calculer le spectre à partir des données de sortie de la FFT et des facteurs de *twiddle* sont faites en algorithmique *fixed point*. Les fonctions SIMD permettent d'effectuer deux ou quatre opérations en parallèle afin de réduire le temps d'exécution.

```
void ne10_mdct_i32_neon::mdct(int16_t *time_signal, int32_t *spectrum)
        // see the twiddling_loops.nlsx file for more details
        // for i from 0 to 254, step 2
        // r[ 0 -> 127, pas 1] = time_signal[ 767 -> 513, pas 2] * c[ 0 -> 127, pas 1] 
// + time_signal[ 768 -> 1022, pas 2] * c[ 0 -> 127, pas 1]
                                                          + time_signal[ 256 -> 510, pas 2] * s[ 0 -> 127, pas 1]
        //
                                                                                                           1, pas 2] * s[ 0 -> 127, pas 1]
        //
                                                          + -time_signal[ 255 ->
       // i[ 0 -> 127, pas 1] = time_signal[ 256 -> 510, pas 2] * c[ 0 -> 127, pas 1]

// + -time_signal[ 255 -> 1, pas 2] * c[ 0 -> 127, pas 1]

// + -time_signal[ 767 -> 513, pas 2] * s[ 0 -> 127, pas 1]
                                                         + -time_signal[ 768 -> 1022, pas 2] * s[ 0 -> 127, pas 1]
        //
        // fft_{in}[i/2].r = time_{signal}[M32-1-i] * cos_{tw}[i] + time_{signal}[M32+i]
                                                                                                                                                                            * cos tw[i]
                                          + time_signal[M2+i]
                                                                                                * sin_tw[i] + (-time_signal[M2-1-i]) * sin_tw[i]
        // fft_in[i/2].i = time_signal[M2+i]
                                                                                                * cos_tw[i] + (-time_signal[M2-1-i]) * cos_tw[i]
                                           + (-time\_signal[M32-1-i]) * sin\_tw[i] + (-time\_signal[M32+i]) * sin\_tw[i]
        // for i from 510 to 256, step 2
        // r[255 -> 128, pas 1] = time_signal[ 257 -> 511, pas 2] * c[255 -> 128, pas 1]
                                                         + -time_signal[ 254 -> 0, pas 2] * c[255 -> 128, pas 1]
+ time_signal[ 766 -> 512, pas 2] * s[255 -> 128, pas 1]
        //
        //
                                                          + time_signal[ 769 -> 1023, pas 2] * s[255 -> 128, pas 1]
        // i [255 -> 128, pas 1] = time_signal[ 766 -> 512, pas 2] * c[255 -> 128, pas 1]
                                                         + time_signal[ 769 -> 1023, pas 2] * c[255 -> 128, pas 1]
+ -time_signal[ 257 -> 511, pas 2] * s[255 -> 128, pas 1]
        //
        //
                                                          + time_signal[ 254 ->
                                                                                                            0, pas 2] * s[255 \rightarrow 128, pas 1]
        // \ fft_{-in}[i/2]. \ r = time\_signal[M32-1-i] \\ * \ cos\_tw[i] + (-time\_signal[-M2+i]) * \ cos\_tw[i] \\ + (-time\_signal[-M2+
                                          + time_signal[M2+i]
                                                                                                * sin_tw[i] + time_signal[M52-1-i] * sin_tw[i]
        // fft_{in}[i/2].i = time_signal[M2+i]
                                                                                                * cos_tw[i] + time_signal[M52-1-i] * cos_tw[i]
                                           + \ \left(-\operatorname{time\_signal}[\operatorname{M32-1-i}]\right) \ * \ \operatorname{sin\_tw}[i] \ + \ \operatorname{time\_signal}[-\operatorname{M2+i}] \quad * \ \operatorname{sin\_tw}[i]
        for (int i = 0; i < MDCT_M2; i += 8)
                // tx.val[0] -> odd indexes
                // tx.val[1] -> even indexes
                int16x4x2_t t1 = vld2_s16 (time_signal+MDCT_M2+i);
                int16x4x2_t t2 = vld2_s16 (time_signal+MDCT_M2-8-i);
                int16x4x2_t t3 = vld2_s16 (time_signal+MDCT_M32+i);
                int16x4x2_t t4 = vld2_s16 (time_signal+MDCT_M32-8-i);
                t2.val[0] = (int16x4_t)vrev64_s32((int32x2_t)vrev32_s16(t2.val[0]));
                                                                                                    // reverse the t2 even values: 0 2 4 6 -> 6 4 2 0
                t2.val[1] = (int16x4_t)vrev64_s32((int32x2_t)vrev32_s16(t2.val[1]));
                                                                                                   // reverse the t2 odd values : 1 3 5 7 -> 7 5 3 1
                t4.val[0] = (int16x4_t)vrev64_s32((int32x2_t)vrev32_s16(t4.val[0]));
                                                                                                    // reverse the t4 even values: 0 2 4 6 -> 6 4 2 0
                t4.val[1] = (int16x4_t)vrev64_s32((int32x2_t)vrev32_s16(t4.val[1]));
                                                                                                 // reverse the t4 odd values : 1 3 5 7 -> 7 5 3 1
```

```
// x_tw.val[0] \rightarrow cos twiddle
// x_tw.val[1] \rightarrow sin twiddle
int16x4x2_t start_tw = vld2_s16(pretwiddle_start+i);
int16x4x2_t end_tw = vld2_s16(pretwiddle_end+i);
// start.val[0] -> real part
// start.val[1] -> imaginary part
int32x4x2_t start;
start.val[0] = vshrq_n_s32(
     vaddq_s32(
         vaddq\_s32
              vmull\_s16 \left(\,t4\,.\,val\,[\,1\,]\,,\;\; start\_tw\,.\,val\,[\,0\,]\right)\,,
              vmull_s16(t3.val[0], start_tw.val[0])),
         vaddq_s32
              vmull_s16(t1.val[0], start_tw.val[1]),
              vmull_s16(vneg_s16(t2.val[1]), start_tw.val[1])))
           7);
start.val[1] = vshrq_n_s32
    vaddq_s32 (
         vaddq_s32
              vmull\_s16 \, (\,t1\,.\,val\,[\,0\,]\,,\ start\_tw\,.\,val\,[\,0\,]\,)\,,
              vmull_s16(vneg_s16(t2.val[1]), start_tw.val[0])),
         vaddq_s32
              vmull_s16(vneg_s16(t4.val[1]), start_tw.val[1]),
              vmull_s16(vneg_s16(t3.val[0]), start_tw.val[1])))
          , 7);
// end.val[0] -> real part
// end.val[1] -> imaginary part
int32x4x2_t end;
end.val[0] = vshrq_n_s32
     vaddq_s32(
         vaddq\_s32\,(\,vmull\_s16\,(\,t1\,.\,val\,[\,1\,]\,,\ end\_tw\,.\,val\,[\,0\,])\,,
         vmull_s16(vneg_s16(t2.val[0]), end_tw.val[0])),
     vaddq_s32
         vmull_s16(t4.val[0], end_tw.val[1]),
          vmull_s16(t3.val[1], end_tw.val[1])))
     , 7);
end.val[1] = vshrq_n_s32
     vaddq_s32(
         vaddq\_s32
               vmull_s16(t4.val[0], end_tw.val[0]),
              vmull_s16(t3.val[1], end_tw.val[0])),
         vmull_s16(vneg_s16(t1.val[1]), end_tw.val[1]),
         vmull\_s16 \,(\,t2\,.\,val\,[\,0\,]\,,\ end\_tw\,.\,val\,[\,1\,]\,)))
// reverse the end part
end.val[0] = (int32x4_t)vrev64q_s32(end.val[0]);
end.val[0] = vcombine_s32(vget_high_s32(end.val[0]), vget_low_s32(end.val[0]));
end.val[1] = (int32x4_t)vrev64q_s32(end.val[1]);
end.val[1] = vcombine_s32(vget_high_s32(end.val[1]), vget_low_s32(end.val[1]));
// store the result
 \begin{array}{lll} vst2q\_s32\,((\,int3\,2\_t & \star)\,fft\_in+i\,, & start\,); \\ vst2q\_s32\,((\,int3\,2\_t & \star)(\,fft\_in+MDCT\_M2-4-i\,/\,2)\,, & end\,); \end{array}
```

```
// perform the FFT
ne10_fft_c2c_1d_int32_neon(fft_out, fft_in, cfg, 0, 0);
// post-twiddling
for (int i = 0; i < MDCT_M2; i += 8)
     // load the fft ouput and reverse the end part
    // fft_out_x.val[0] \rightarrow real part
    // fft_out_x.val[1] -> imaginary part
    int32x4x2\_t \quad fft\_out\_start \ = \ vld2q\_s32 \ ((\ int32\_t \ *) \ fft\_out+i \ );
    int32x4x2_t fft_out_end = vld2q_s32((int32_t *) fft_out+MDCT_M-8-i);
     fft_out_end . val[0] = (int32x4_t)vrev64q_s32(fft_out_end . val[0]);
    fft_out_end.val[0] = vcombine_s32(vget_high_s32(fft_out_end.val[0]),
                                             vget_low_s32(fft_out_end.val[0]));
    fft_{out}_{end}.val[1] = (int32x4_t)vrev64q_s32(fft_{out}_{end}.val[1]);
    fft_out_end.val[1] = vcombine_s32(vget_high_s32(fft_out_end.val[1]),
                                             vget_low_s32(fft_out_end.val[1]));
    // load the twiddle factors
    // x_tw.val[0] \rightarrow cos twiddle
    // x_tw.val[1] \rightarrow sin twiddle
    int32x4x2_t start_tw = vld2q_s32(posttwiddle_start+i);
    int32x4x2_t end_tw = vld2q_s32(posttwiddle_end+i);
    int32x4x2_t spectrum_start;
    spectrum_start.val[0] = vshrq_n_s32(vaddq_s32(
         vqrdmulhq\_s32 \, (\, vnegq\_s32 \, (\, fft\_o\, ut\_start \, .\, val\, [\, 0\, ]) \, , \quad start\_tw \, .\, val\, [\, 0\, ]) \, ,
         vqrdmulhq\_s32 \, (\, vnegq\_s32 \, (\, fft\_out\_start \, . \, val \, [\, 1\, ]) \, ) \, , \quad start\_tw \, . \, val \, [\, 1\, ])) \, , \quad 8);
     spectrum_start.val[1] = vshrq_n_s32(vaddq_s32(
         vqrdmulhq_s32(vnegq_s32(fft_out_end.val[0]), end_tw.val[1]),
         vqrdmulhq_s32(fft_out_end.val[1], end_tw.val[0])), 8);
    int32x4x2_t spectrum_end;
    spectrum_end.val[0] = vshrq_n_s32(vaddq_s32(
         vqrdmulhq\_s32 \, (\, vnegq\_s32 \, (\, fft\_out\_end \, . \, val \, [\, 0\, ]) \, , \ end\_tw \, . \, val \, [\, 0\, ]) \, ,
         vqrdmulhq_s32(vnegq_s32(fft_out_end.val[1]), end_tw.val[1])), 8);
    spectrum_end.val[1] = vshrq_n_s32(vaddq_s32(
         vqrdmulhq_s32(vnegq_s32(fft_out_start.val[0]), start_tw.val[1]),
         vqrdmulhq\_s32\left(\,fft\_o\,u\,t\_s\,t\,a\,r\,t\,.\,val\,[\,1\,]\,,\;\;st\,a\,r\,t\_t\,w\,.\,val\,[\,0\,]\right))\,,\;\;8\,);
     spectrum_end.val[0] = (int32x4_t)vrev64q_s32(spectrum_end.val[0]);
    spectrum_end.val[0] = vcombine_s32(vget_high_s32(spectrum_end.val[0]),
                                              vget_low_s32(spectrum_end.val[0]));
    spectrum_end.val[1] = (int32x4_t)vrev64q_s32(spectrum_end.val[1]);
    spectrum_end.val[1] = vcombine_s32(vget_high_s32(spectrum_end.val[1]),
                                              vget_low_s32(spectrum_end.val[1]));
    // store the result
    vst2q_s32((int32_t *)spectrum+i, spectrum_start);
    vst2q\_s32\,((\,int32\_t \quad \star\,)(\,spectrum\,+\!MD\!CT\_M\!-\!8\!-\!i\,)\,,\ spectrum\_end\,)\,;
```

L Comparaison des spectres de fréquences produits par les MDCT

L.1 Code source

```
#include <iomanip >
#include <iostream >
#include <fstream >
#include < cstring >
#include "ref_mdct.h"
#include "sin_wave.h"
#ifdef I32_C
                // fixed point arithmetic plain C
#include "ne10_mdct_i32_c.h"
#define NE10 MDCT
                                ne10_mdct_i32_c
#define INPUT DATA
                               int16_t
#define OUTPUT_DATA
                               int32_t
#define GENERATE_SIN
                                sin_int
#define REF_MDCT
                                ref_int_mdct
#elif I32_NEON // fixed point arithmetic with Neon optimizations
#include "ne10_mdct_i32_neon.h"
#define NE10_MDCT
                                ne10_mdct_i32_neon
#define INPUT DATA
                                int16 t
#define OUTPUT_DATA
                               int32_t
#define GENERATE_SIN
                                sin_int
#define REF_MDCT
                                ref_int_mdct
                    // floating point arithmetic
#include "fftw3_mdct_f32.h"
#include "ne10_mdct_f32_c.h"
#define NE10_MDCT
                                ne10_mdct_f32_c
#define INPUT_DATA
                                float
#define OUTPUT_DATA
                                float
#define GENERATE_SIN
                                sin_float
#define REF_MDCT
                                ref_float_mdct < float >
#endif
* @brief comparison of the MDCTs algorithms with a single tone signal (200Hz, sampled at 48kHz):
   prints the spectrums generated by the Ne10, ref and FFTW3 MDCTs in a CSV file
int main(void)
    // generate the time signal (200 Hz)
   INPUT_DATA time_signal[MDCT_WINDOW_LEN] __attribute__ ((aligned (16)));
   GENERATE_SIN(time_signal, MDCT_WINDOW_LEN, 0.9, 200.0, 0.0, FS);
    // perform the reference MDCT
    OUTPUT_DATA ref_mdct_spectrum [MDCT_M] __attribute__((aligned(16)));
    memset(\&ref\_mdct\_spectrum\;,\;\;0\;,\;\;(MDCT\_M)* \\ \textbf{sizeof}\;(OUTPUT\_DATA\;)\;);
    REF_MDCT(time_signal, ref_mdct_spectrum);
```

```
// perform the FFTW3 MDCT
#ifdef F32_C
    OUTPUT_DATA fftw_mdct_spectrum[MDCT_M] __attribute__ ((aligned(16)));
    memset(&fftw_mdct_spectrum, 0, (MDCT_M)* sizeof(OUTPUT_DATA));
    fftw3_mdct_f32 fftw3_mdct;
    fftw3_mdct.mdct(time_signal, fftw_mdct_spectrum);
#endif
    // perform the Ne10 MDCT
    OUTPUT_DATA ne10_mdct_spectrum[MDCT_M] __attribute__ ((aligned(16)));
    memset(\&\,ne\,10\_mdct\_spectrum\;,\;\;0\;,\;\;(MDCT\_M)*\,\textit{size}\,\textit{of}\,(OUTPUT\_DATA\,)\,)\;;
    NE10_MDCT ne10_mdct;
    ne10_mdct.mdct(time_signal, ne10_mdct_spectrum);
    // print the results in CSV file
    std::ofstream csv_file;
#ifdef I32_NEON
    csv_file.open("comp_mdct_i32_neon.csv");
    csv_file << "Frequency_(Hz), Ne10_MDCT_i32_Neon_spectrum, Ref_MDCT_spectrum" << std::endl;</pre>
# elif I32_C
    csv_file.open("comp_mdct_i32_c.csv");
    csv_file << "Frequency_(Hz), Ne10_MDCT_i32_plain_C_spectrum, Ref_MDCT_spectrum" << std::endl;
#else
    csv_file.open("comp_mdct_f32.csv");
    csv_file << "Frequency_(Hz), Ne10_MDCT_f32_spectrum, FFTW3_f32_spectrum, Ref_MDCT_spectrum"
        << std::endl;
#endif
    for (int i = 0; i < MDCT_M; ++i)
        csv_file << (i+1.0)*FS/MDCT_WINDOW_LEN << ","
             << std::abs(ne10_mdct_spectrum[i]) << ","
#ifdef F32 C
            << std :: abs(fftw_mdct_spectrum[i]) << ","
#endif
             << std :: abs(ref_mdct_spectrum[i]) << std :: endl;
    csv_file.close();
    return 0;
```

L.2 Code source

```
# Comparison of the MDCT spectrums
# i32 plain C
add_executable(comp_mdct_i32_c test/validation/mdct_spectrum.cpp
    src/sin_wave.cpp src/ref_mdct.cpp src/ne10_mdct_i32_c.cpp)
target_compile_definitions(comp_mdct_i32_c PUBLIC -DI32_C)
target_link_libraries(comp_mdct_i32_c NE10)
```

M Mesure des performances des MDCT Ne10 et MDCT de référence

M.1 Code source

Code permettant de mesurer les performances des MDCT de *Ne10* en *float 32 plain C*, *integer 32 plain C*, *integer 32* avec optimisation Neon et de la MDCT de référence en *double* (en fonction de la variable de préprocesseur définie à la compilation). Le code mesure et affiche le temps d'exécution moyen et l'écart type. Ces informations sont calculées sur un nombre d'exécution donné en paramètre à l'exécutable. Les MDCT sont testées avec le même signal sinusoïdal en entrée dont la valeur par défaut est de 200 Hz.

```
#include <iostream >
#include < cstring >
#include "args_parser.h"
#include "mdct_constants.h"
#include "sin_wave.h"
#include "Timers.h"
#ifdef FIXED_POINT_C
                      // fixed point arithmetic
#include "ne10_mdct_i32_c.h"
#define INPUT_DATA
                                int16_t
#define OUTPUT_DATA
                               int32_t
#define GENERATE_SIN
                               sin_int
#define MDCT
                                ne10 mdct i32 c
#elif FIXED_POINT_NEON // fixed point arithmetic
#include "ne10_mdct_i32_neon.h"
#define INPUT_DATA
                                int16\_t
#define OUTPUT DATA
                               int32 t
#define GENERATE_SIN
                               sin_int
#define MDCT
                                ne10_mdct_i32_neon
                      // floating point arithmetic
#elif FLOATING_POINT
#include "ne10_mdct_f32_c.h"
#define INPUT_DATA
                                float
#define OUTPUT_DATA
                                float
#define GENERATE_SIN
                                sin_float
#define MDCT
                                ne10_mdct_f32_c
                        // reference algorithm in floating point arithmetic
#else
#include "ref_mdct.h"
#define INPUT DATA
                                double
#define OUTPUT_DATA
                                double
                                sin_float
#define GENERATE_SIN
#endif
```

```
/**
* @brief Run the MDCT on a single frame x times
 * the signal is a single tone configurable via the --sin parameter (200Hz by default)
* the number of runs is setted by the --run parameter (1 by default)
int main(int argc, char ** argv)
{
    // initialize the parameters
    params p;
    trv
       p = parse_args(argc, argv);
    catch(const std::runtime_error &err)
        std::cerr << err.what() << std::endl;
        usage();
        return 1;
    // print which MDCT will be tested
#ifdef FIXED POINT C
    std::cout << "MDCT_Ne10_i32_plain_C:_"
        << p.runs << "_runs_with_a_single_tone_signal_(" << p.frequency << "Hz)" << std::endl;</pre>
#elif FIXED_POINT_NEON
    std::cout << "MDCT Ne10 i32 Neon:"
       << p.runs << "_runs_with_a_single_tone_signal_(" << p.frequency << "Hz)" << std::endl;</pre>
#elif FLOATING_POINT
    std::cout << "MDCT_Ne10_f32_plain_C:_"
        << p.runs << "_runs_with_a_single_tone_signal_(" << p.frequency << "Hz)" << std::endl;</pre>
#else
    std::cout << "Reference_MDCT: _ "
        << p.runs << "_runs_with_a_single_tone_signal_(" << p.frequency << "Hz)" << std :: endl;</pre>
#endif
    // generate the time signal
    INPUT_DATA time_signal[MDCT_WINDOW_LEN]__attribute__ ((aligned (16)));
    memset(&time_signal, 0, MDCT_WINDOW_LEN*sizeof(INPUT_DATA));
    GENERATE_SIN(time_signal, MDCT_WINDOW_LEN, 0.9, p.frequency, 0.0, FS);
    // initialize an empty spectrum
    OUTPUT_DATA mdct_spectrum[MDCT_M]__attribute__((aligned(16)));
    memset(&mdct_spectrum, 0, MDCT_M* size of (OUTPUT_DATA));
    // perform the MDCT x times
    EvsHwLGPL::CTimers timer;
    int64_t *runtimes = static_cast <int64_t *> (malloc(p.runs * sizeof(int64_t)));
#ifdef REF
    for (unsigned i = 0; i < p.runs; ++ i) {
        timer. Start();
        ref_float_mdct <INPUT_DATA > (time_signal, mdct_spectrum);
        timer.Stop();
        runtimes[i] = timer.GetTimeElapsed();
```

```
#else
   MDCT ne10_mdct;
    for (unsigned i = 0; i < p.runs; ++i) {
        timer.Start();
        ne10_mdct.mdct(time_signal, mdct_spectrum);
        timer.Stop();
        runtimes[i] = timer.GetTimeElapsed();
#endif
    // compute the average run time
    double avg = 0.0;
    for (unsigned i = 0; i < p.runs; ++i) avg += static_cast < double > (runtimes[i]);
    avg = avg / static_cast < double > (p.runs);
    std::cout << "average_run_time:_" << avg << "_ns" << std::endl;
    // compute the standard deviation
    double dev = 0.0;
    for (unsigned i = 0; i < p.runs; ++i) dev += static_cast < double > (runtimes[i]) - avg;
    dev = dev * dev / static_cast < double > (p.runs);
    dev = sqrt(dev);
    std::cout << "standard_deviation:_" << dev << std::endl;</pre>
    // clean
    free (runtimes);
    return 0;
```

M.2 Compilation

Commandes CMake pour la compilation des différents exécutables de tests de performance des MDCT:

- la variable FLOATING_POINT permet de compiler l'exécutable run_mdct_f32_c pour tester la MDCT basée sur la FFT de *Ne10* en *float 32 plain C*;
- la variable FIXED_POINT_C permet de compiler l'exécutable run_mdct_i32_c pour tester la MDCT basée sur la FFT de *Ne10* en *integer 32 plain C*;
- la variable FIXED_POINT_NEON permet de compiler l'exécutable run_mdct_i32_neon pour tester la MDCT basée sur la FFT de *Ne10* en *integer 32* avec optimisations Neon;
- la variable REF permet de compiler l'exécutable run_mdct_ref pour tester la MDCT de référence en double;

N Mesure des performances de la MDCT FFTW3 en float 32

N.1 Code source

Code permettant de mesurer les performances de la MDCT basée sur la FFT de *FFTW3* en *float 32*. Le code mesure et affiche le temps d'exécution moyen et l'écart type. Ces informations sont calculées sur 10 000 000 d'exécutions. La MDCT est testée avec le même signal sinusoïdal en entrée dont la valeur est définie à 440 Hz.

```
#include <iostream >
#include < cstring >
#include "fftw3_mdct_f32.h"
#include "sin_wave.h"
#include "Timers.h"
#define RUNS
                     10000000
#define FREQUENCY
int main()
    // print which MDCT will be tested
    std::cout << "MDCT_FFTW3_f32_plain_C:_"
        << RUNS << "_runs_with_a_single_tone_signal_(" << FREQUENCY << "Hz)" << std :: endl;</pre>
    // generate the time signal
    float time_signal[MDCT_WINDOW_LEN];
    sin_float(time_signal, MDCT_WINDOW_LEN, 0.9, FREQUENCY, 0.0, FS);
    // initialize an empty spectrum
    float spectrum [MDCT_M];
    memset(spectrum, 0, MDCT_M*sizeof(float));
    // initialize the configuration
    fftw3_mdct_f32 fftw3_mdct;
    // perform the MDCT
    EvsHwLGPL::CTimers timer;
    int64_t *runtimes = static_cast <int64_t *>(malloc(RUNS * sizeof(int64_t)));
    for (int i = 0; i < RUNS; ++i)
        timer. Start();
        fftw3_mdct.mdct(time_signal, spectrum);
        timer.Stop();
        runtimes[i] = timer.GetTimeElapsed();
    // compute the average run time
    double avg = 0.0;
    for (int i = 0; i < RUNS; ++i) avg += static_cast < double > (runtimes[i]);
    avg = avg / static_cast < double > (RUNS);
    std::cout << "average "run" time: " << avg << "" ns" << std::endl;\\
    // compute the standard deviation
    double dev = 0.0;
    for (int i = 0; i < RUNS; ++i) dev += static_cast < double > (runtimes [i]) - avg;
    dev = dev * dev / static_cast < double > (RUNS);
    dev = sqrt(dev);
    std::cout << "standard_deviation:_" << dev << std::endl;</pre>
```

```
// clean
free(runtimes);
return 0;
}
```

N.2 Compilation

Commandes CMake pour la compilation de l'exécutable de tests de performance de la MDCT basée sur la FFT de FFTW3 en float 32.